

tutaj ładna strona tytułowa wstęp teoretyczny i przegląd literatury i bibliografia


Spis treści

1	Zbiory danych	3
1.1	Charakterystyka zbioru MNIST	3
1.2	Charakterystyka zbioru CIFAR-10	3
2	Środowisko badawcze	5
2.1	Przygotowanie konfiguracji, ścieżek oraz funkcji pomocniczych	5
2.2	Przygotowanie danych oraz procesu trenowania	6
2.3	Metody generowania perturbacji	8
2.4	Metody XAI	9
2.5	Metryki oceny wyjaśnień	10
2.6	Orkiestracja eksperymentu	11
3	Trening modeli oraz przebieg badań	13
3.1	Trening modeli klasyfikacyjnych	13
3.2	Konfiguracja i przebieg eksperymentów	14
4	Analiza wyników badań dla zbioru MNIST	17
4.1	Wpływ szumu Gaussa na wyjaśnienia generowane metodą Integrated Gradients	17
4.2	Wpływ ataku FGSM na wyjaśnienia generowane metodą Integrated Gradients .	20
4.3	Wpływ szumu Gaussa na wyjaśnienia generowane metodą Occlusion	23
4.4	Wpływ ataku FGSM na wyjaśnienia generowane metodą Occlusion	26
5	Analiza wyników badań dla zbioru CIFAR-10	30
5.1	Wpływ szumu Gaussa na wyjaśnienia generowane metodą Integrated Gradients	30
5.2	Wpływ ataku FGSM na wyjaśnienia generowane metodą Integrated Gradients .	33
5.3	Wpływ szumu Gaussa na wyjaśnienia generowane metodą Occlusion	35
5.4	Wpływ ataku FGSM na wyjaśnienia generowane metodą Occlusion	38
6	Analiza porównawcza wyników	42
7	Podsumowanie	48

1. Zbiory danych

1.1. Charakterystyka zbioru MNIST

Pierwszym obiektem, na którym przeprowadzono badania jest popularny w uczeniu maszynowym zbiór danych MNIST (ang. *Modified National Institute of Standards and Technology*). Składający się łącznie około 70 000 obrazów (60 000 przykładów treningowych oraz około 10 000 przykładów testowych), przedstawia ręcznie pisane cyfry od 0 do 9. Każdy z obrazów domyślnie posiada rozmiar 28x28 pikseli, co w efekcie daje 784 piksele (cechy) dla każdego rozważanego obrazu. Cały zbiór danych reprezentowany jest w skali szarości, co oznacza, że każdy piksel przyjmuje wartość z zakresu od 0 do 255, gdzie 0 oznacza kolor czarny, natomiast 255 kolor biały. Przykładowe obrazy z tego zbioru danych przedstawiono na rysunku 1.1.




Rysunek 1.1. Przykładowe obrazy ze zbioru MNIST

Cechą zbioru MNIST jest jego zbalansowany charakter, co oznacza, że każda z etykiet jest reprezentowana przez podobną ilość przykładów uczących w zbiorze. Zbalansowany zbiór danych jest kluczowy w zadaniach klasyfikacji, ponieważ pozwala na uniknięcie problemu tendencyjności modelu podczas późniejszej klasyfikacji nowych danych, których model wcześniej nie widział. Zdecydowano się na wykorzystanie opisywanego zbioru ze względu na jego popularność i prostotę. Skala szarości, która przekłada się na prostotę zbioru danych pozwala na wstępne zapoznanie się ze specyfiką wyników generowanych przez badane metody wyjaśnialnej sztucznej inteligencji, co stanowi dobrą bazę do dalszych eksperymentów z bardziej złożonymi zbiorami danych.

1.2. Charakterystyka zbioru CIFAR-10

Kolejnym zbiorem danych, który wykorzystano w badaniach jest również popularny zbiór CIFAR-10 (ang. *Canadian Institute for Advanced Research*). Zbiór ten charakteryzuje się podobną ilością przykładów, co omawiany wcześniej MNIST. Podobnie jak poprzednik, CIFAR-10 posiada 10 klas, jednak w przeciwieństwie do MNIST, klasy te reprezentują różne

obiekty, takie jak samochody, samoloty, ptaki etc. Od poprzednika różni się również rozmiarem obrazów. W tym przypadku mamy do czynienia z danymi o rozmiarze 32x32 pikseli, co daje 1024 cechy. Z racji, że CIFAR-10 jest zbiorem danych kolorowych, liczbę tę należy pomnożyć przez 3 (kanały RGB), co daje łącznie 3072 cechy dla każdego obrazu. Przykładowe obrazy z tego zbioru danych przedstawiono na rysunku 1.2.



Rysunek 1.2. Przykładowe obrazy ze zbioru CIFAR-10

Analogicznie jak w przypadku MNIST, CIFAR-10 jest zbiorem danych zbalansowanym, co oznacza, że każda z klas jest reprezentowana przez podobną ilość przykładów uczących. Wybór omawianego zbioru danych był podyktowany potrzebą zbadania metod wyjaśnialnej sztucznej inteligencji w warunkach danych bardziej złożonych, które odzwierciedlają realistyczne scenariusze (różne gatunki zwierząt, obiekty, tło itp.). Ze względu na swoją różnorodność stanowi doskonały test dla badanych metod, pozwalając na ocenę ich skuteczności w kontekście danych odzwierciedlających świat rzeczywisty.

2. Środowisko badawcze

W niniejszym rozdziale przedstawiono wszystkie elementy środowiska badawczego, które zostały wykorzystane w przeprowadzonych eksperymentach. Opisano przygotowanie konfiguracji, danych, modeli klasyfikacyjnych, metod XAI, metod generowania perturbacji oraz metryki oceny wyjaśnień. W całym eksperymencie zdecydowano się na podejście obiektowe i modułowe, co oznacza, że każdy z elementów środowiska badawczego został przygotowany w sposób niezależny, a następnie połączony w jedną całość. Takie podejście pozwoliło na elastyczność i możliwość łatwej modyfikacji poszczególnych elementów w przypadku potrzeby modyfikacji parametrów eksperymentu lub wprowadzenia nowych metod XAI. W kolejnych sekcjach przedstawiono szczegółowe informacje dotyczące każdego z elementów środowiska badawczego, co pozwoli na pełne zrozumienie procesu przeprowadzonych eksperymentów oraz interpretację uzyskanych wyników.

2.1. Przygotowanie konfiguracji, ścieżek oraz funkcji pomocniczych

Pracę nad środowiskiem badawczym rozpoczęto od zaimplementowania zestawu klas konfiguracyjnych oraz zestawu funkcji pomocniczych, których zadaniem było uporządkowanie parametrów eksperymentów i ograniczenie powtarzania tych samych fragmentów kodu w różnych częściach programu.

Do przechowywania parametrów wykorzystano klasy danych oznaczone dekoratorem `@dataclass`. Klasa `IGConfig` zawierała ustawienia metody Integrated Gradients, takie jak liczba kroków całkowania `n_steps` oraz wartość bazowa `baseline_value`. Wartość bazowa była wykorzystywana podczas tworzenia tensora odniesienia dla analizowanego obrazu. Klasa `OcclusionConfig` przechowywała parametry metody Occlusion. Zawierała osobne ustawienia dla zbiorów MNIST oraz CIFAR-10, obejmujące krok przesuwania okna `strides` oraz rozmiar okna okluzji `sliding_window_shapes`. Rozdzielenie tych parametrów pozwalało dostosować działanie metody do charakterystyki analizowanego zbioru danych. W klasie tej zdefiniowano również wartość bazową wykorzystywaną podczas zastępowania fragmentów obrazu.

Klasa `ExperimentConfig` grupowała parametry związane z przebiegiem eksperymentów. Obejmowała wartości odchylenia standardowego szumu Gaussa, wartości parametru `epsilon` dla ataku FGSM, procent pikseli uwzględnianych w metryce Top-K IoU, liczbę kroków w procedurze Deletion AUC oraz wartość bazową stosowaną podczas usuwania pikseli. Dzięki temu wszystkie najważniejsze parametry eksperymentalne były zebrane w jednym miejscu i mogły być łatwo modyfikowane bez ingerencji w kod poszczególnych klas. Klasa `TrainingConfig` zawierała podstawowe ustawienia procesu uczenia modelu, takie jak rozmiar batcha, liczba epok, współczynnik uczenia oraz udział zbioru walidacyjnego. Parametry te były wykorzystywane podczas przygotowywania danych oraz trenowania modeli klasyfikacyjnych.

W projekcie zdefiniowano również klasę `Paths`, której zadaniem było przechowywanie ścieżek do najważniejszych katalogów projektu. Na podstawie lokalizacji pliku wyznaczano katalog główny projektu, a następnie katalog danych oraz katalog przeznaczony do zapisu modeli.

Dodatkowe funkcje pomocnicze umieszczono w pliku `utils.py`. Funkcja `get_device()` automatycznie wybierała urządzenie obliczeniowe, zwracając GPU w przypadku dostępności technologii CUDA albo CPU w przeciwnym przypadku. Funkcja `tensor_to_img()` służyła do przekształcania tensora obrazu do postaci możliwej do wyświetlenia. W ramach tej operacji tensor był przenoszony na CPU, konwertowany do tablicy NumPy, a następnie przekształcany z zakresu wartości $[-1,1]$ do zakresu $[0,1]$. Funkcja `plot_image()` ujednolicała sposób wyświetlania obrazów i map atrybucji. Przyjmowała obiekt osi wykresu, obraz, tytuł oraz opcjonalne parametry mapy kolorów i zakresu wartości. Dzięki temu możliwe było stosowanie spójnego sposobu wizualizacji w różnych częściach eksperymentu. W pliku pomocniczym zdefiniowano także funkcję `initialize_resnet18()`, która tworzyła model ResNet18. W zależności od przekazanego parametru model mógł zostać zainicjalizowany z wagami wstępnie wytrenowanymi lub bez nich. Ostatnia warstwa była zastępowana nową warstwą, której liczba wyjść odpowiadała liczbie klas analizowanego zbioru danych. Funkcja `load_model_weights()` umożliwiała wczytanie zapisanych wag modelu, przeniesienie modelu na odpowiednie urządzenie oraz przełączenie go w tryb ewaluacji.

2.2. Przygotowanie danych oraz procesu trenowania

Następnie przystąpiono do przygotowania klasy `DataManager`, która służyła do ujednolicenia procesu przygotowania danych wykorzystywanych w badaniach. Jej głównym zadaniem było zapewnienie wspólnego interfejsu do obsługi zbioru MNIST oraz CIFAR-10, obejmującego pobieranie danych, ich wstępne przetwarzanie, wyodrębnienie ze zbioru treningowego zbioru walidacyjnego, pobranie zbioru testowego oraz obiektów `Data Loader`, które umożliwiały iterację po danych w trakcie trenowania modeli. Dzięki temu możliwe było łatwe zarządzanie danymi oraz zapewnienie spójności w procesie przygotowania danych dla eksperymentów. W konstruktorze klasy określano ścieżkę do katalogu danych na podstawie klasy `Paths` oraz tworzonego obiektu `TrainingConfig`, z którego pobierano parametry związane z treningiem, takie jak rozmiar batcha oraz udział zbioru walidacyjnego. Klasa przechowywała również mapowanie indeksów klas na ich nazwy. Dla zbioru MNIST indeksy odpowiadały cyfrom od 0 do 9, natomiast dla zbioru CIFAR-10 przypisano im nazwy klas, takie jak `airplane`, `automobile`, `bird` czy `cat`. Metoda `get_class_names()` umożliwiała pobranie tego mapowania dla wskazanego zbioru danych.

Istotnym elementem klasy `DataManager` jest metoda `get_transform()`, która definiuje sposób przetwarzania obrazów w zależności od zbioru danych. Obrazy są przekształcane do rozmiaru 224x224 pikseli, następnie zamieniane na obiekty typu `tensor`. Ostatnim etapem przygotowywania danych dla modelu jest normalizacja. W badaniach została ona

przeprowadzona zgodnie ze wzorem 2.1.

$$x_{norm} = \frac{x - \mu}{\sigma} \quad (2.1)$$

gdzie:

x – wartość wejściowa piksela,

μ – średnia wartość pikseli dla danego zbioru,

σ – odchylenie standardowe wartości pikseli.

Wartości μ i σ zostały przyjęte na poziomie 0.5. Podstawiając te wartości do wzoru 2.1 otrzymujemy:

$$x_{norm} = \frac{x - 0.5}{0.5} = 2x - 1 \quad (2.2)$$

Po transformacji obrazów do obiektu typu tensor wartości pikseli zawierają się w przedziale $[0, 1]$. Podstawiając te wartości do wzoru 2.2 otrzymujemy, że po normalizacji wartości pikseli zawierają się w przedziale $[-1, 1]$. Taka normalizacja pozwala na wycentrowanie danych wejściowych wokół zera, co może prowadzić do stabilniejszego przebiegu procesu uczenia oraz efektywniejszej optymalizacji parametrów modelu. Należy również uwzględnić dodatkowy krok transformacyjny w przypadku zbioru MNIST. Ponieważ obrazy w tym zbiorze są jednokanałowe (skala szarości), konieczne było dodanie dodatkowego kroku transformacyjnego, który rozszerza pojedynczy kanał do trzech kanałów, ponieważ taki właśnie format wymagany jest przez architekturę sieci użytej w badaniach.

Metoda `get_dataset()` pozwala na utworzenie odpowiedniego obiektu zbioru danych z biblioteki PyTorch, nakładając jednocześnie zdefiniowane wcześniej kroki transformacyjne. W celu wydzielenia zbioru walidacyjnego służącego do oceny modeli podczas procesu uczenia zaimplementowana została metoda `get_train_val_datasets()`. Omawiana metoda pobiera pełny zbiór treningowy i wydobywa z niego zbiór walidacyjny o wielkości determinowanej przez parametr `val_ratio`, który przyjęto na poziomie 0.1. Metoda `get_test_dataset()` stanowi wygodny sposób na pobranie zbioru testowego dla danego zbioru danych nakładając na niego odpowiednie transformacje. Ostatnią główną funkcjonalnością klasy `DataManager` jest metoda `get_data_loaders()`, która tworzy obiekty `DataLoader` dla zbioru treningowego, walidacyjnego oraz testowego. Obiekty te umożliwiają iterację po danych w trakcie trwania procesu uczenia modeli.

Po przygotowaniu klasy odpowiedzialnej za zarządzanie danymi przystąpiono do implementacji modułu `ModelTrainer`, którego zadaniem było uporządkowanie procesu treningu, walidacji oraz ewaluacji modeli klasyfikacyjnych wykorzystywanych w badaniach. Klasa ta pozwalała oddzielić logikę uczenia modelu od pozostałych elementów projektu.

Obiekt klasy `ModelTrainer` przyjmował model sieci neuronowej, urządzenie wykonujące obliczenia oraz nazwy klas występujących w analizowanym zbiorze danych. W konstruktorze

określano również ścieżkę zapisu modelu na podstawie klasy Paths oraz tworzono obiekt TrainingConfig, z którego pobierano parametry konieczne do przeprowadzenia treningu. Funkcja straty została zdefiniowana jako CrossEntropyLoss, natomiast jako optymalizator wykorzystano algorytm Adam. Model był następnie przenoszony na wskazane urządzenie obliczeniowe. Klasa przechowywała również historię procesu uczenia w postaci słownika zawierającego wartości funkcji straty oraz dokładności dla zbioru treningowego i walidacyjnego. Dzięki temu możliwa była późniejsza analiza przebiegu uczenia modelu.

Metoda `train_one_epoch()` realizowała pojedynczą epokę treningową. Dla kolejnych batchy wykonywana była propagacja w przód, obliczanie funkcji straty, propagacja wsteczna oraz aktualizacja wag modelu. Dla każdej epoki obliczana była średnia wartość funkcji straty oraz dokładność klasyfikacji na zbiorze treningowym. W metodzie `validate()` dokonywana była ocena modelu na zbiorze walidacyjnym w danej epoce. Wynikiem działania metody były średnia strata walidacyjna oraz dokładność klasyfikacji na zbiorze walidacyjnym. Metoda `fit()` pełniła rolę orkiestratora dwóch poprzednich metod, wywołując je w pętli po liczbie zadanych epok treningowych. Wyniki metod `train_one_epoch()` i `validate()` zapisywane były w historii treningu. Informacje w niej zawarte, czyli dokładność oraz wartości funkcji straty, były wykorzystywane do oceny jakości procesu uczenia. Po zakończeniu treningu model mógł zostać oceniony na zbiorze testowym za pomocą metody `evaluate()`, która generowała predykcje dla wszystkich przykładów testowych oraz raport klasyfikacyjny zawierający metryki dla poszczególnych klas. Ostatnią funkcjonalnością klasy ModelTrainer była metoda `save_model()`, która umożliwiała zapis wag modelu do pliku, dając możliwość załadowania i wykorzystania modelu w późniejszych badaniach.

2.3. Metody generowania perturbacji

W celu generowania zakłóconych wersji obrazów wejściowych wykorzystywanych w eksperymentach nad stabilnością metod XAI zaimplementowano klasę Perturbations. Jej zadaniem było przygotowanie danych poddanych perturbacjom, które następnie wykorzystywano do porównania map atrybucji uzyskanych dla obrazów oryginalnych oraz zaburzonych.

Obiekt klasy Perturbations przyjmował model predykcyjny oraz urządzenie obliczeniowe. W konstruktorze określono również minimalną i maksymalną dopuszczalną wartość pikseli po perturbacji. Zgodnie z opisem procesu przygotowania danych w sekcji 2.2, dane wejściowe zostały znormalizowane do zakresu $[-1, 1]$, dlatego wartości graniczne ustawiono odpowiednio na -1 oraz 1. Po wygenerowaniu perturbacji wartości obrazu były ograniczane do tego przedziału, co zapewniało zgodność danych wejściowych z zakresem wykorzystywanym podczas trenowania modelu.

Pierwszą zaimplementowaną metodą perturbacji była metoda `gaussian()`, która dodawała do obrazu wejściowego szum Gaussa. W pierwszym kroku tworzono kopię tensora wejściowego i przenoszono ją na wybrane urządzenie obliczeniowe. Następnie generowano tensor losowego

szumu o takim samym rozmiarze jak obraz wejściowy. Wygenerowany szum był skalowany przez parametr σ , a następnie dodawany do obrazu zgodnie ze wzorem ???. Wynikowy tensor był ograniczany do zakresu $[-1, 1]$ i zwracany jako zakłócona wersja obrazu wejściowego.

Drugą metodą perturbacji była metoda `fgsm()`, która generowała obraz zaburzony zgodnie z procedurą FGSM opisaną wzorem ??. Metoda przyjmowała tensor wejściowy, klasę docelową oraz wartość parametru ϵ . Na początku tworzono kopię obrazu wejściowego, przenoszono ją na urządzenie obliczeniowe oraz włączano śledzenie gradientów względem wejścia. Następnie obraz przekazywano do modelu, a dla wskazanej klasy docelowej obliczano wartość funkcji straty. Po wyzerowaniu wcześniejszych gradientów wykonywano propagację wsteczną, dzięki czemu uzyskiwano gradient funkcji straty względem obrazu wejściowego. Na jego podstawie tworzono perturbację o skali określonej przez parametr ϵ , którą dodawano do obrazu wejściowego. Po ponownym wyzerowaniu gradientów wynikowy obraz był ograniczany do zakresu $[-1, 1]$ i zwracany jako przykład zaburzony. W obu metodach operacje wykonywane były na kopii tensora wejściowego, tak, aby oryginał został nienaruszony.

2.4. Metody XAI

Kolejnym etapem przygotowywania środowiska badawczego było zaimplementowanie klas odpowiedzialnych za generowanie map atrybucji (wyjaśnień): `IGExplainer` oraz `OcclusionExplainer`. Obie klasy wykorzystywały implementacje metod dostępnych w bibliotece `Captum`, a ich zadaniem było ujednolicenie sposobu generowania wyjaśnień oraz przetwarzania otrzymanych atrybucji do formatu wykorzystywanego w dalszych eksperymentach.

Klasa `IGExplainer` została zaimplementowana w celu generowania wyjaśnień metodą `Integrated Gradients`. Do konstruktora klasy przekazywano model predykcyjny oraz urządzenie obliczeniowe. Wewnątrz konstruktora tworzony był obiekt konfiguracyjny `IGConfig`, z którego pobierano parametry metody, takie jak liczba kroków `n_steps`, która stanowiła przybliżenie całkowania ze wzoru ??? oraz wartość bazowa `baseline_value`. Dodatkowo inicjalizowano obiekt `IntegratedGradients` z biblioteki `Captum`, powiązany z analizowanym modelem. Główną funkcjonalność klasy stanowiła metoda `explain()`, która przyjmowała tensor wejściowy oraz identyfikator klasy docelowej. Tensor wejściowy był przenoszony na wskazane urządzenie obliczeniowe, a następnie włączano dla niego śledzenie gradientów. Kolejnym krokiem było utworzenie tensora bazowego o takiej samej strukturze jak obraz wejściowy, wypełnionego wartością określoną w konfiguracji. Atrybucje wyznaczano za pomocą metody `attribute()`, do której przekazywano obraz wejściowy, tensor bazowy, klasę docelową oraz liczbę kroków określoną w `IGConfig`.

Klasa `OcclusionExplainer` pełniła analogiczną rolę dla metody `Occlusion`. Do jej konstruktora przekazywano model predykcyjny, urządzenie obliczeniowe oraz nazwę analizowanego zbioru danych. Wewnątrz klasy tworzony był obiekt `OcclusionConfig`,

zawierający parametry metody osobno dla zbiorów MNIST oraz CIFAR-10. Inicjalizowano również obiekt `Occlusion` z biblioteki `Captum`. W metodzie `explain()` klasy `OcclusionExplainer` tensor wejściowy przenoszono na urządzenie obliczeniowe oraz tworzono tensor bazowy wypełniony wartością `baseline_value`. Następnie, w zależności od wartości pola `dataset`, wybierano odpowiednie parametry `strides` oraz `sliding_window_shapes`. Atrybucje wyznaczano następnie za pomocą metody `attribute()`, przekazując do niej tensor wejściowy, parametry okna, tensor bazowy oraz klasę docelową.

Metoda ta agregowała atrybucje wyznaczone dla poszczególnych kanałów obrazu do jednej mapy atrybucji oraz przygotowywała trzy warianty reprezentacji wyniku: `raw`, `abs` i `deletion`. Pierwszy wariant zachowywał oryginalny znak atrybucji, drugi przedstawiał ogólną siłę wpływu niezależnie od znaku sumując wartości bezwzględne, natomiast trzeci pozostawiał jedynie dodatnie wartości atrybucji. Tak przygotowane mapy były następnie wykorzystywane w metrykach oceny stabilności wyjaśnień modeli.

2.5. Metryki oceny wyjaśnień

W celu mierzalnej oceny stabilności oraz użyteczności map atrybucji zaimplementowano klasę `Metrics`. Klasa ta zawierała zestaw metod obliczających metryki wykorzystywane w dalszych eksperymentach.

Pierwszą zaimplementowaną metryką było podobieństwo cosinusowe, realizowane przez metodę `cosine_similarity()`. Metoda przyjmowała dwie mapy atrybucji, które w pierwszym kroku były przekształcane do postaci jednowymiarowych wektorów. Następnie obliczano stosunek ich iloczynu skalarnego do iloczynu długości obu wektorów zgodnie ze wzorem $\frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$. W celu zabezpieczenia obliczeń przed potencjalnym błędem dzielenia przez zero do mianownika dodawano niewielką stałą $1e-8$.

Drugą zaimplementowaną metryką była Top-K IoU, obliczana przez metodę `topk_iou()`. Podobnie jak w przypadku podobieństwa cosinusowego, mapy atrybucji były najpierw przekształcane do postaci jednowymiarowych wektorów. Następnie na podstawie parametru `top_k_percent` wyznaczano liczbę pikseli należących do grupy najbardziej istotnych elementów. Dla każdej mapy wybierano indeksy pikseli o najwyższych wartościach atrybucji, a wartość metryki wyznaczano jako stosunek liczności części wspólnej tych zbiorów do liczności ich sumy.

Ostatnią zaimplementowaną metryką była Deletion AUC, której obliczanie realizowała metoda `deletion_auc()`. Jej działanie rozpoczynało się od utworzenia kopii obrazu wejściowego oraz uporządkowania pikseli zgodnie z ich istotnością określoną przez przekazaną mapę atrybucji. Następnie, w kolejnych krokach, najbardziej istotne piksele były stopniowo zastępowane wartością bazową. Liczbę etapów tego procesu określał parametr `steps`, natomiast domyślną wartość bazową przyjęto na poziomie -1, zgodnie z zakresem wartości danych po normalizacji. Po każdej modyfikacji obrazu wyznaczano prawdopodobieństwo przypisane przez

model klasie docelowej i zapisywano je wraz z odpowiadającym mu udziałem usuniętych pikseli. Na podstawie otrzymanych wartości konstruowano krzywą opisującą zmianę pewności modelu wraz ze wzrostem liczby usuniętych pikseli, a następnie obliczano pole pod tą krzywą za pomocą funkcji `auc()` dostępnej w bibliotece `scikit-learn`.

2.6. Orkiestracja eksperymentu

Głównym modulem odpowiedzialnym za przeprowadzanie eksperymentów była klasa `XAIExperiment`. Jej zadaniem była orkiestracja wcześniej przygotowanych elementów środowiska badawczego. Klasa ta umożliwiała przeprowadzenie kompletnej procedury porównywania wyjaśnień uzyskanych dla obrazów oryginalnych oraz ich zaburzonych wersji.

Do konstruktora klasy przekazywano model, urządzenie obliczeniowe, nazwy klas, zestaw poprawnie sklasyfikowanych przykładów oraz jeden z obiektów klas wyjaśniających opisanych w sekcji 2.4. Na podstawie przekazanych przykładów wyznaczano również listę analizowanych klas. Wewnątrz klasy tworzone obiekty `Perturbations`, odpowiedzialny za generowanie zaburzonych obrazów, obiekt `Metrics`, wykorzystywany do obliczania wartości metryk, oraz obiekt `ExperimentConfig`, zawierający parametry eksperymentów.

Metoda `iter_clean_examples()` umożliwiała iterację po wszystkich obrazach wykorzystywanych w eksperymencie. Dla każdej klasy zwracany był identyfikator klasy, numer przykładu oraz tensor obrazu przygotowany w formacie wymaganym przez model. Rozwiązanie to pozwalało wykonywać obliczenia nie tylko dla pojedynczego przykładu danej klasy, lecz także dla wielu przykładów, co umożliwiało późniejsze uśrednianie wyników. Do generowania zaburzonych wersji obrazów wykorzystano metodę `get_perturbed_tensor()`. W zależności od wartości parametru `perturbation_type` metoda wywoływała odpowiednią funkcję klasy `Perturbations`. Dla wartości `gaussian` generowany był obraz z dodanym szumem Gaussa, natomiast dla wartości `fgsm` tworzony był obraz zaburzony metodą FGSM. Metoda `run_similarity_metrics()` odpowiadała za obliczanie metryk podobieństwa pomiędzy mapami atrybucji obrazów oryginalnych i zaburzonych. W pierwszym kroku tworzone pamięć podręczną map atrybucji dla obrazów oryginalnych, aby uniknąć ich wielokrotnego przeliczania dla każdej wartości perturbacji. Do obliczania podobieństwa wykorzystywano wariant mapy `abs`, czyli sumę wartości bezwzględnych atrybucji po kanałach obrazu. Wybór tego wariantu wynikał z celu analizowanych metryk. Podobieństwo cosinusowe oraz Top-K IoU miały oceniać przede wszystkim stabilność położenia obszarów istotnych dla modelu, a nie kierunek ich wpływu na predykcję. Z tego względu uwzględniano całkowitą siłę atrybucji niezależnie od jej znaku. Następnie dla kolejnych wartości parametru perturbacji generowano zaburzone obrazy, obliczano dla nich mapy atrybucji oraz porównywano je z wcześniej zapisanymi mapami obrazów oryginalnych. Wyniki zapisywano w postaci listy słowników zawierających typ perturbacji, wartość parametru, identyfikator klasy, nazwę klasy, numer przykładu oraz wartości obliczonych metryk. Ostatecznie wyniki zwracano jako obiekt `DataFrame` biblioteki

pandas. Metoda `run_deletion_auc()` została przygotowana do oceny zmian wartości metryki Deletion AUC dla obrazów oryginalnych i zaburzonych. W tym przypadku wykorzystywano wariant mapy `deletion`, zawierający jedynie dodatnie wartości atrybucji. Taki wybór był związany z charakterem procedury Deletion AUC, w której kolejno zastępowano wartością bazową piksele uznane za najbardziej wspierające predykcję analizowanej klasy. Ujemne wartości atrybucji mogły oznaczać obszary działające przeciwnie względem danej klasy, dlatego nie były uwzględniane podczas wyboru pikseli usuwanych w tej metryce. Podobnie jak w przypadku metryk podobieństwa, najpierw tworzono pamięć podręczną wyników dla obrazów oryginalnych. Dla każdego przykładu zapisywano predykcję modelu, pewność modelu względem klasy docelowej oraz wartość Deletion AUC obliczoną na podstawie mapy `deletion`. W dalszej części procedury, dla każdej wartości perturbacji, generowano obraz zaburzony i sprawdzano predykcję modelu oraz jego pewność względem klasy docelowej. Następnie wyznaczano mapę atrybucji dla obrazu zaburzonego i obliczano wartość Deletion AUC.

W klasie zaimplementowano również metody pomocnicze służące do agregacji wyników. Metoda `make_pivot()` tworzyła tabelę przestawną, w której wartości wybranej metryki były uśredniane dla poszczególnych klas i poziomów perturbacji. Metoda `summarize_similarity()` grupowała wyniki metryk podobieństwa względem wartości perturbacji i obliczała średnie oraz odchylenia standardowe dla podobieństwa cosinusowego i Top-K IoU. Analogicznie metoda `summarize_deletion()` agregowała wyniki związane z Deletion AUC, pewnością modelu oraz liczbą zmian predykcji.

Zastosowanie klasy `XAIExperiment` pozwoliło uporządkować przebieg eksperymentów i zapewnić jednolity sposób obliczania wyników dla różnych metod wyjaśniania, typów perturbacji oraz analizowanych zbiorów danych.

3. Trening modeli oraz przebieg badań

W niniejszym rozdziale przedstawiono przebieg procesu trenowania modeli predykcyjnych użytych w badaniach. Opisano również konfigurację oraz przebieg całych eksperymentów dla rozważanych zbiorów danych.

3.1. Trening modeli klasyfikacyjnych

Przygotowanie badań rozpoczęto od wytrenowania modelu klasyfikacyjnego dla zbioru MNIST. Zdecydowano się na wykorzystanie architektury ResNet18 z wagami wstępnie wytrenowanymi, a ostatnią warstwę klasyfikacyjną zastąpiono nową warstwą w pełni połączoną, dostosowaną do liczby klas występujących w danym zbiorze. W przypadku zbiorów MNIST oraz CIFAR-10 liczba klas wynosiła 10.

Proces dostrajania zrealizowano z wykorzystaniem wcześniej opisanej w sekcji 2.2 klasy `ModelTrainer`. Dla obu zbiorów zastosowano ten sam schemat treningu, obejmujący uczenie na zbiorze treningowym oraz kontrolę jakości na zbiorze walidacyjnym dla ostatniej epoki treningowej. Dodatkowo w tabeli zamieszczono również ocenę na zbiorze testowym. Różnice pomiędzy eksperymentami dotyczyły wykorzystywanego zbioru danych oraz liczby epok dostrajania modelu (dla zbioru MNIST liczba epok równa 3, dla CIFAR-10 liczba epok wynosiła 7). Większa liczba epok dla CIFAR-10 wynikała z większej złożoności danych. Dla każdego zbioru monitorowano wartość funkcji straty oraz dokładność klasyfikacji na zbiorze treningowym i walidacyjnym. Po zakończeniu dostrajania modele oceniono na zbiorach testowych. Wartości metryk dla rozważanych zbiorów przedstawiono w tabeli 3.1.

Tabela 3.1. Zestawienie wartości dokładności dla zbioru MNIST oraz CIFAR-10 dla wszystkich etapów treningu

Zbiór danych	Acc_{train}	Acc_{val}	Acc_{test}
MNIST	0.9915	0.9938	0.9937
CIFAR-10	0.9707	0.8862	0.8806


Uzyskane wyniki wskazywały, że oba modele osiągnęły skuteczność wystarczającą do dalszych badań nad stabilnością metod wyjaśniania. W przypadku zbioru MNIST dokładność na zbiorach treningowym, walidacyjnym i testowym była bardzo zbliżona oraz przekraczała 99%. Dla zbioru CIFAR-10 uzyskano niższą dokładność niż dla MNIST, co było oczekiwane ze względu na większą złożoność obrazów naturalnych oraz większą różnorodność cech wizualnych. Widoczna różnica pomiędzy dokładnością treningową a walidacyjną i testową wskazywała, że zadanie klasyfikacji było trudniejsze, a model w większym stopniu dopasował się do danych treningowych. Mimo to dokładność testowa na poziomie 88% została uznana za wystarczającą

do przeprowadzenia dalszych eksperymentów. Modele zostały zapisane do plików, w celu późniejszego ich wczytania i użycia w eksperymentach.


3.2. Konfiguracja i przebieg eksperymentów

Po przygotowaniu i ocenie modeli klasyfikacyjnych przystąpiono do właściwych eksperymentów związanych z analizą stabilności metod wyjaśniania. Eksperymenty przeprowadzono oddzielnie dla zbiorów MNIST oraz CIFAR-10, a dla każdego z nich rozważono dwa typy perturbacji: szum Gaussa oraz atak FGSM. Ogólny schemat przeprowadzania badań był taki sam. Różnice dotyczyły wykorzystywanego zbioru danych, typu perturbacji oraz zakresu analizowanych klas.

W każdym przypadku punktem wyjścia było wczytanie wcześniej dostrojonego modelu ResNet18 oraz zbioru testowego. Następnie wybierano obrazy, dla których model dokonywał poprawnej klasyfikacji. W przypadku zbioru MNIST analizą objęto wszystkie dziesięć klas, natomiast dla zbioru CIFAR-10 wybrano cztery klasy: airplane, automobile, bird oraz cat. Ograniczenie liczby klas dla CIFAR-10 wynikało z większej złożoności obrazów oraz wyższego kosztu obliczeniowego generowania map atrybucji dla danych naturalnych. Dodatkowo dla CIFAR-10 zastosowano próg pewności predykcji równy 0.99, aby do analizy trafiały przykłady sklasyfikowane przez model z wysoką pewnością. W celu zmaksymalizowania wiarygodności przeprowadzanych badań dla każdej analizowanej klasy przygotowano dwa zestawy przykładów. Pierwszy z nich służył do obliczania metryk ilościowych i obejmował po 10 poprawnie sklasyfikowanych obrazów na klasę. Drugi zestaw przeznaczono do wizualizacji i zawierał po jednym reprezentatywnym przykładzie dla każdej klasy. Takie rozdzielenie pozwoliło uniknąć opierania wniosków ilościowych na pojedynczych obrazach, a jednocześnie umożliwiło czytelne przedstawienie przykładowych map atrybucji w części wynikowej pracy. Przykładowy efekt perturbacji obrazów wejściowych pokazano na rysunku 3.1 oraz 3.2.



Rysunek 3.1. Przykłady nałożonego szumu Gaussa na obrazy wejściowe



Rysunek 3.2. Przykłady ataku FGSM na obrazy wejściowe

W eksperymentach wykorzystano metody wyjaśniania, których implementacja została przedstawiona w rozdziale 2.4. Dla każdej z nich tworzone osobny obiekt eksperymentu, ale procedura oceny pozostawała taka sama. Najpierw generowano mapę atrybucji dla obrazu

oryginalnego, następnie tworzone jego zaburzona wersję, a później ponownie wyznaczano mapę atrybucji dla obrazu po perturbacji. Pozwalało to bezpośrednio porównać wyjaśnienia uzyskane przed i po modyfikacji obrazu wejściowego. Dla szumu Gaussa analizowano kolejne wartości parametru σ , natomiast dla FGSM kolejne wartości parametru ε , zgodnie z konfiguracją eksperymentu. W części wizualizacyjnej wykorzystywano również pojedyncze, silniejsze wartości perturbacji, takie jak $\sigma = 0,8$ oraz $\varepsilon = 0,5$. Ich celem nie było zastąpienie pełnej analizy ilościowej, lecz jej uzupełnienie poprzez pokazanie w czytelny sposób, jak wyraźna perturbacja wpływa na obraz wejściowy oraz odpowiadającą mu mapę atrybucji. Ponadto wartości te należy traktować jako test obciążeniowy, którego celem było sprawdzenie granic stabilności metod XAI, a nie jako typowy poziom zakłócenia danych wejściowych.

Ocena stabilności wyjaśnień była prowadzona w dwóch uzupełniających się etapach. W pierwszym obliczano metryki podobieństwa pomiędzy mapą atrybucji obrazu oryginalnego i mapą obrazu zaburzonego. W tym celu wykorzystywano wariant mapy abs, ponieważ analizowano przede wszystkim zgodność położenia obszarów istotnych dla modelu, niezależnie od znaku atrybucji. Na tej podstawie obliczano podobieństwo cosinusowe oraz Top-K IoU. Następnie obliczano metrykę Deletion AUC. W tym przypadku wykorzystywano wariant mapy deletion, zawierający dodatnie wartości atrybucji. Wynikało to z charakteru tej procedury, w której stopniowo zastępowano wartością bazową piksele uznane za wspierające predykcję analizowanej klasy. Oprócz samej wartości Deletion AUC zapisywano również pewność modelu względem klasy docelowej oraz informację o tym, czy perturbacja doprowadziła do zmiany predykcji.


Wyniki poszczególnych eksperymentów zapisywano w postaci tabelarycznej. W przypadku metryk podobieństwa rejestrowano wartość parametru perturbacji, średnią wartość podobieństwa cosinusowego oraz Top-K IoU, a także odpowiadające im odchylenia standardowe. Pozwalało to ocenić nie tylko ogólny spadek podobieństwa map atrybucji wraz ze wzrostem siły perturbacji, ale również zmienność wyników pomiędzy analizowanymi przykładami. Dla metryki Deletion AUC zapisywano średnie wartości uzyskane dla obrazów oryginalnych oraz zaburzonych, wraz z odpowiadającymi im odchyleniami standardowymi. Dodatkowo uwzględniano średnią pewność modelu względem klasy docelowej przed i po wprowadzeniu perturbacji oraz liczbę przypadków, w których predykcja modelu uległa zmianie.

4. Analiza wyników badań dla zbioru MNIST

W niniejszym rozdziale przedstawiono analizę wyników badań wyjaśnień metodą Integrated Gradients oraz Occlusion dla zbioru MNIST.

4.1. Wpływ szumu Gaussa na wyjaśnienia generowane metodą Integrated Gradients


Analizę rozpoczęto od oceny map atrybucji wygenerowanych metodą Integrated Gradients dla niezaburzonych obrazów ze zbioru MNIST. Przykładowe wyniki przedstawiono na rysunku 4.1.



Rysunek 4.1. Mapy atrybucji Integrated Gradients dla obrazów niezaburzonych

Na rysunku można było zauważyć, że dla analizowanych cyfr najwyższe wartości atrybucji koncentrowały się w obszarach odpowiadających właściwemu kształtowi liczby skupiając się na kluczowych dla każdej cyfry elementach geometrii, takich jak charakterystyczne zaokrąglenia, przecięcia linii czy punkty zwrotne. W przypadku cyfr o zamkniętych pętlach, takich jak 0, 6, 8 czy 9, model wyraźnie zaznaczał ich obwody, co pozwalało mu skutecznie odróżnić te cyfry od siebie nawzajem oraz od bardziej liniowych konstrukcji. Podobnie w sytuacjach, gdzie kluczowe znaczenie miało przecięcie linii, jak miało to miejsce w cyfrach 2, 4 czy 7, mapy atrybucji wskazywały precyzyjnie na te krytyczne złącza, potwierdzając, że stanowiły one najważniejszą informację dla podjęcia decyzji klasyfikacyjnej. W przypadku obrazów MNIST taka interpretacja była szczególnie czytelna, ponieważ tło obrazu było jednorodne, a najważniejsza informacja wizualna znajdowała się w obrębie samej cyfry.

Mapy Integrated Gradients dla obrazów niezaburzonych stanowiły punkt odniesienia dla dalszej analizy stabilności. W kolejnym kroku zbadano mapy atrybucji przykładów niezaszumionych z zaszumionymi. Porównanie przedstawiono na rysunku 4.2.



Rysunek 4.2. Porównanie map atrybucji Integrated Gradients obrazów niezaszumionych i zaszumionych

Po dodaniu szumu Gaussa mapy atrybucji zachowywały częściową zgodność z mapami uzyskanymi dla obrazów oryginalnych. Najważniejsze obszary nadal znajdowały się w pobliżu kształtu cyfry, jednak atrybucje stawały się bardziej rozproszone. Widoczne były również dodatkowe aktywacje poza właściwym obszarem cyfry, co wskazywało, że zakłócenia tła wpływały na sposób wyznaczania istotności przez metodę Integrated Gradients.

W celu zweryfikowania tych obserwacji przeprowadzono analizę ilościową. Dla kolejnych poziomów szumu porównano mapy atrybucji obrazów oryginalnych i zaburzonych za pomocą podobieństwa cosinusowego oraz metryki Top-K IoU. Pozwoliło to ocenić, w jakim stopniu zmiany widoczne na mapach przekładały się na mierzalny spadek stabilności wyjaśnień. Wartości metryk przedstawiono w tabeli 4.1. Wyniki pokazywały systematyczny spadek stabilności wyjaśnień wraz ze wzrostem wartości parametru σ . Dla najmniejszego poziomu szumu, $\sigma = 0,010$, średnie podobieństwo cosinusowe wynosiło 0,901, natomiast średnia wartość Top-K IoU była równa 0,764. Oznaczało to, że przy bardzo słabym zakłóceniu mapy atrybucji pozostawały w dużym stopniu zgodne z mapami uzyskanymi dla obrazów oryginalnych. Wraz ze wzrostem intensywności szumu obie metryki stopniowo malały. Dla największej analizowanej wartości, $\sigma = 0,800$, podobieństwo cosinusowe spadło do 0,598, a Top-K IoU do 0,400. Spadek podobieństwa cosinusowego wskazywał, że ogólny rozkład wartości atrybucji stawał się coraz mniej zbliżony do rozkładu uzyskanego dla obrazów niezaburzonych. Jednocześnie spadek Top-K IoU oznaczał,

że zmieniało się również położenie najbardziej istotnych pikseli. Odchylenia standardowe dla podobieństwa cosinusowego były stosunkowo niewielkie i mieściły się w przedziale od 0,018 do 0,036, co wskazywało na dość spójny trend spadkowy w analizowanych przykładach. Odchylenia standardowe Top-K IoU początkowo nieznacznie wzrosły, a następnie malały dla większych poziomów szumu.

Tabela 4.1. Zestawienie metryk podobieństwa dla różnych wartości parametru σ dla zbioru MNIST i metody Integrated Gradients

σ	$\overline{cos}$	SD_{cos}	$\overline{IoU}_K$	SD_{IoU}
0.010	0.901	0.026	0.764	0.078
0.030	0.839	0.025	0.681	0.087
0.050	0.813	0.022	0.646	0.088
0.075	0.793	0.022	0.619	0.086
0.100	0.780	0.022	0.600	0.085
0.150	0.758	0.018	0.574	0.081
0.200	0.736	0.020	0.553	0.079
0.300	0.709	0.023	0.519	0.073
0.500	0.659	0.033	0.465	0.065
0.800	0.598	0.036	0.400	0.057

Po zbadaniu metryk podobieństwa przystąpiono do analizy metryki Deletion AUC w celu sprawdzenia, jak usuwanie pikseli wskazanych przez mapę atrybucji jako istotne wpływało na pewność modelu względem analizowanej klasy. Dzięki temu możliwe było uzupełnienie wcześniejszej oceny stabilności o informację, czy obszary wyróżniane przez metodę Integrated Gradients rzeczywiście miały znaczenie dla decyzji klasyfikacyjnej. Wyniki dla kolejnych wartości parametru σ przedstawiono w tabeli 4.2. Wartości $\overline{AUC}_c$ oraz $\overline{Conf}_c$ pozostawały stałe dla wszystkich poziomów szumu, ponieważ odnosiły się do tych samych obrazów niezaburzonych, które stanowiły punkt odniesienia w eksperymencie. Średnia wartość Deletion AUC dla obrazów oryginalnych wyniosła 0,279, natomiast średnia pewność modelu względem klasy docelowej była bardzo wysoka i wynosiła 0,997. Dla obrazów zaburzonych można było zauważyć wyraźną zmianę wartości Deletion AUC wraz ze wzrostem parametru σ . Przy najmniejszym poziomie szumu, $\sigma = 0,010$, średnia wartość $\overline{AUC}_p$ wynosiła 0,411, a więc była wyższa niż dla obrazów oryginalnych. Następnie wartość ta systematycznie malała, osiągając 0,241 dla $\sigma = 0,100$, 0,145 dla $\sigma = 0,300$ oraz 0,104 dla największego poziomu szumu, $\sigma = 0,800$. Oznaczało to, że wraz ze wzrostem intensywności zakłócenia zmieniał się wpływ usuwania pikseli wskazanych przez mapę atrybucji na pewność modelu. Interpretując te wyniki, należało uwzględnić również średnią pewność modelu dla obrazów zaburzonych. Dla małych wartości σ pozostawała ona bardzo wysoka i zbliżona do wartości uzyskanej dla obrazów oryginalnych. Przykładowo dla $\sigma = 0,010$ wynosiła 0,997, a dla $\sigma = 0,100$ nadal utrzymywała się na poziomie 0,991. Oznaczało to, że niewielki szum nie zaburzał istotnie decyzji modelu. Dopiero dla większych wartości parametru widoczny był wyraźniejszy spadek pewności,


szczególnie dla $\sigma = 0,500$, gdzie wyniosła ona 0,905, oraz dla $\sigma = 0,800$, gdzie spadła do 0,703. Wraz ze wzrostem poziomu szumu rosła także liczba przypadków, w których predykcja modelu uległa zmianie. Dla wartości σ do 0,075 nie odnotowano żadnych zmian predykcji, natomiast dla $\sigma = 0,100$ pojawiła się pierwsza taka zmiana. Przy silniejszych perturbacjach liczba zmian wzrastała, osiągając 7 przypadków dla $\sigma = 0,500$ oraz 24 przypadki dla $\sigma = 0,800$. Pokazywało to, że przy największych poziomach szumu wyniki Deletion AUC należało interpretować ostrożnie, ponieważ były one powiązane nie tylko z właściwościami map atrybucji, ale również z pogorszeniem stabilności samej klasyfikacji.

Tabela 4.2. Wpływ wartości szumu Gaussa na metrykę Deletion AUC, pewność predykcji oraz liczbę zmian predykcji dla zbioru MNIST i metody Integrated Gradients

σ	$\overline{AUC}_c$	$SD_{AUC,c}$	$\overline{AUC}_p$	$SD_{AUC,p}$	$\overline{Conf}_c$	$\overline{Conf}_p$	N_{chg}
0.010	0.279	0.236	0.411	0.276	0.997	0.997	0
0.030	0.279	0.236	0.381	0.266	0.997	0.996	0
0.050	0.279	0.236	0.328	0.274	0.997	0.995	0
0.075	0.279	0.236	0.287	0.281	0.997	0.994	0
0.100	0.279	0.236	0.241	0.267	0.997	0.991	1
0.150	0.279	0.236	0.203	0.256	0.997	0.986	1
0.200	0.279	0.236	0.171	0.235	0.997	0.981	1
0.300	0.279	0.236	0.145	0.222	0.997	0.961	3
0.500	0.279	0.236	0.121	0.200	0.997	0.905	7
0.800	0.279	0.236	0.104	0.172	0.997	0.703	24

4.2. Wpływ ataku FGSM na wyjaśnienia generowane metodą Integrated Gradients

Przystąpiono do analizy wpływu ataku FGSM na wyjaśnienia generowane metodą Integrated Gradients. Tak jak w poprzednim eksperymencie, punktem odniesienia były mapy atrybucji wyznaczone dla obrazów niezaburzonych. Porównanie map atrybucji przedstawiono na rysunku 4.3. Po zastosowaniu ataku FGSM mapy atrybucji uległy zauważalnym zmianom względem map otrzymanych dla obrazów oryginalnych. W wielu przypadkach główny zarys cyfry pozostawał jeszcze widoczny, jednak atrybucje były mniej zwarte i bardziej rozproszone. Tutaj - w przeciwieństwie do szumu Gaussa - szczególnie widoczne były osłabienia fragmentów, które wcześniej tworzyły wyraźny kształt cyfr. Mapy po ataku stały się wyraźnie mniej czytelne i trudniej było wskazać jednoznaczny obszar odpowiedzialny za decyzję modelu. Zauważono również pojedyncze aktywacje w tle poza geometrią cyfr.



Rysunek 4.3. Porównanie map atrybucji Integrated Gradients obrazów niezaatakowanych i zaatakowanych

W tabeli 4.3 pokazano wyniki metryk dla map atrybucji po zastosowaniu ataku FGSM na obrazach wejściowych dla różnych wartości ϵ . Wskazywały one na systematyczny spadek zgodności map wraz ze wzrostem wartości parametru ϵ . Dla najmniejszej wartości perturbacji $\epsilon = 0,010$ średnie podobieństwo cosinusowe wynosiło 0,853, a średnia wartość Top-K IoU 0,707. Oznaczało to, że nawet przy niewielkiej wartości parametru ϵ mapy atrybucji po ataku różniły się zauważalnie od map uzyskanych dla obrazów oryginalnych. Wraz ze wzrostem siły ataku obie metryki stopniowo malały. Dla największej analizowanej wartości $\epsilon = 0,500$ podobieństwo cosinusowe spadło do 0,541, natomiast Top-K IoU do 0,390. Spadek podobieństwa cosinusowego wskazywał, że ogólny rozkład atrybucji stawał się coraz mniej podobny do rozkładu uzyskanego dla obrazów niezaburzonych. Jednocześnie obniżenie wartości Top-K IoU oznaczało, że zmieniało się położenie pikseli uznawanych przez metodę za najistotniejsze. Odchylenia standardowe dla podobieństwa cosinusowego rosły wraz ze wzrostem wartości ϵ , od 0,023 dla $\epsilon = 0,010$ do 0,067 dla $\epsilon = 0,500$. Mogło to wskazywać, że silniejsze perturbacje wpływały na poszczególne przykłady w bardziej zróżnicowany sposób. W przypadku Top-K IoU odchylenia standardowe pozostawały na zbliżonym poziomie, co sugerowało, że spadek zgodności najważniejszych obszarów był względnie konsekwentny w całym analizowanym zbiorze przykładów.

Tabela 4.3. Zestawienie metryk podobieństwa dla różnych wartości parametru ε dla zbioru MNIST i metody Integrated Gradients

ε	$\overline{cos}$	SD_{cos}	$\overline{IoU}_K$	SD_{IoU}
0.010	0.853	0.023	0.707	0.090
0.030	0.801	0.020	0.638	0.097
0.050	0.777	0.021	0.610	0.095
0.075	0.755	0.024	0.584	0.093
0.100	0.736	0.028	0.564	0.091
0.150	0.701	0.034	0.534	0.089
0.200	0.672	0.039	0.510	0.086
0.300	0.623	0.049	0.466	0.082
0.400	0.579	0.060	0.426	0.083
0.500	0.541	0.067	0.390	0.083


Tabela 4.4 przedstawia wartości metryki Deletion AUC dla ataku FGSM przy różnych wartościach ε . Dla obrazów po zastosowaniu FGSM widoczny był wyraźny spadek wartości $\overline{AUC}_p$ wraz ze wzrostem parametru ε . Dla najmniejszej wartości $\varepsilon = 0,010$ średnia wartość Deletion AUC wynosiła 0,369, natomiast dla $\varepsilon = 0,050$ spadła do 0,231. Przy dalszym zwiększaniu siły ataku spadek był jeszcze bardziej widoczny: dla $\varepsilon = 0,200$ wartość $\overline{AUC}_p$ wyniosła 0,088, a dla największej analizowanej wartości $\varepsilon = 0,500$ jedynie 0,047. Dla małych wartości ε model nadal zachowywał wysoką pewność względem klasy docelowej. Przykładowo dla $\varepsilon = 0,010$ średnia pewność wynosiła 0,993, a predykcja nie zmieniła się ani razu. Jednak już dla $\varepsilon = 0,030$ pojawiły się 2 zmiany predykcji, a pewność spadła do 0,977. Oznaczało to, że nawet niewielka perturbacja FGSM zaczynała wpływać na decyzje modelu. Dla większych wartości ε wpływ ataku był znacznie silniejszy. Średnia pewność modelu spadła z 0,879 dla $\varepsilon = 0,100$ do 0,630 dla $\varepsilon = 0,200$, a następnie do 0,167 dla $\varepsilon = 0,500$. Równocześnie liczba zmienionych predykcji wzrosła z 9 dla $\varepsilon = 0,100$ do 33 dla $\varepsilon = 0,200$ oraz 83 dla $\varepsilon = 0,500$. Tak duży wzrost liczby zmian predykcji pokazywał, że dla wysokich wartości ε atak FGSM znacząco zaburzał działanie modelu klasyfikacyjnego.

Tabela 4.4. Wpływ wartości parametru ϵ ataku FGSM na metrykę Deletion AUC, pewność predykcji oraz liczbę zmian predykcji dla zbioru MNIST i metody Integrated Gradients

ϵ	$\overline{AUC}_c$	$SD_{AUC,c}$	$\overline{AUC}_p$	$SD_{AUC,p}$	$\overline{Conf}_c$	$\overline{Conf}_p$	N_{chg}
0.010	0.279	0.236	0.369	0.264	0.997	0.993	0
0.030	0.279	0.236	0.302	0.258	0.997	0.977	2
0.050	0.279	0.236	0.231	0.240	0.997	0.955	4
0.075	0.279	0.236	0.171	0.207	0.997	0.918	7
0.100	0.279	0.236	0.136	0.180	0.997	0.879	9
0.150	0.279	0.236	0.105	0.144	0.997	0.778	18
0.200	0.279	0.236	0.088	0.122	0.997	0.630	33
0.300	0.279	0.236	0.067	0.087	0.997	0.391	56
0.400	0.279	0.236	0.055	0.065	0.997	0.244	74
0.500	0.279	0.236	0.047	0.056	0.997	0.167	83

4.3. Wpływ szumu Gaussa na wyjaśnienia generowane metodą Occlusion

W kolejnym etapie eksperymentów zbadano wpływ zaburzeń obrazów wejściowych na wyjaśnienia generowane metodą Occlusion. Na rysunku 4.4 pokazano przykładowe mapy atrybucji dla przykładów niezaburzonych.




Rysunek 4.4. Mapy atrybucji Occlusion dla obrazów niezaburzonych

W przypadku tej metody wyjaśnienia mają charakter bardziej obszarowy niż punktowy, ponieważ istotność wyznaczana jest na podstawie wpływu zasłaniania fragmentów obrazu na decyzję modelu. Z tego powodu mapy nie pokazywały szczegółowo każdego elementu konturu cyfry, lecz

wskazywały większe regiony, których obecność była istotna dla klasyfikacji. Dla analizowanych cyfr najwyższe wartości atrybucji koncentrowały się głównie w pobliżu fragmentów znaku charakterystycznych dla danej klasy. W przypadku cyfr takich jak 0, 6, 8 czy 9 widoczne były aktywacje w rejonach odpowiadających pętlom oraz łukom. Dla cyfr o bardziej liniowej strukturze, takich jak 1 czy 7, istotne obszary obejmowały przede wszystkim główne kreski tworzące kształt cyfry. Oznaczało to, że mimo mniej szczegółowego charakteru map, metoda wskazywała obszary zgodne z intuicyjnie istotnymi cechami cyfr.

Następnie zbadano mapy atrybucji przykładów niezaszumionych z zaszumionymi przez szum Gaussa. Porównanie przedstawiono na rysunku 4.5.



Rysunek 4.5. Porównanie map atrybucji Occlusion obrazów niezaszumionych i zaszumionych

Mapy wygenerowane metodą Occlusion zachowały ogólną strukturę widoczną dla obrazów oryginalnych. Najważniejsze obszary nadal znajdowały się w pobliżu fragmentów tworzących kształt cyfr, co oznaczało, że metoda w dużej mierze wskazywała podobne regiony mimo zakłócenia obrazu wejściowego. W porównaniu z mapami dla obrazów niezaburzonych można było jednak zauważyć pewne osłabienie intensywności atrybucji oraz częściowe rozmycie granic istotnych obszarów. Wpływ szumu był szczególnie widoczny w przypadku cyfr, dla których mapa Occlusion już w wersji niezaburzonej była mniej jednoznaczna, na przykład dla cyfr 3 oraz 5. Po dodaniu zakłócenia aktywacje stawały się słabsze i mniej zwarte, przez co trudniej było wskazać jeden wyraźny obszar odpowiedzialny za decyzję modelu. Na podstawie samej analizy wizualnej można było więc zauważyć, że szum Gaussa nie powodował gwałtownej degradacji map Occlusion.

Następnie przystąpiono do zbadania metryk podobieństwa, których wartości pokazano w tabeli 4.5. Wyniki wskazywały, że metoda Occlusion zachowywała bardzo wysoką stabilność dla małych i średnich poziomów zakłócenia. Dla najmniejszych wartości parametru σ podobieństwo cosinusowe było równe 1. Dla $\sigma = 0,010$ oraz $\sigma = 0,030$ średnia wartość tej metryki wynosiła 1,000, co oznaczało pełną zgodność ogólnego rozkładu atrybucji pomiędzy obrazami oryginalnymi i zaszumionymi. Również Top-K IoU przyjmowało bardzo wysokie wartości, odpowiednio 0,990 oraz 0,981, co pokazywało, że najważniejsze regiony wskazywane przez metodę prawie całkowicie się pokrywały. Wraz ze wzrostem wartości σ obie metryki zaczęły stopniowo maleć, jednak spadek ten był znacznie łagodniejszy niż w przypadku map generowanych metodą Integrated Gradients. Dla $\sigma = 0,200$ podobieństwo cosinusowe nadal wynosiło 0,990, a Top-K IoU 0,879, co wskazywało na zachowanie bardzo dużej zgodności map mimo wyraźniejszego zakłócenia obrazu. Dopiero dla najwyższych poziomów szumu widoczny był silniejszy spadek stabilności. Dla $\sigma = 0,500$ podobieństwo cosinusowe wynosiło 0,956, a Top-K IoU 0,755, natomiast dla $\sigma = 0,800$ wartości te spadły odpowiednio do 0,890 oraz 0,624. Różnica pomiędzy wartościami podobieństwa cosinusowego i Top-K IoU pokazywała, że ogólny rozkład map pozostawał stabilny nawet przy silnym szumie, ale lokalizacja najbardziej istotnych regionów ulegała większym zmianom. Odchylenia standardowe były bardzo niskie dla małych poziomów szumu, co oznaczało, że stabilność map była podobna dla większości analizowanych przykładów. Wraz ze wzrostem wartości σ odchylenia stopniowo rosły, szczególnie dla Top-K IoU, gdzie osiągnęły 0,128 dla $\sigma = 0,800$. Sugerowało to, że silny szum wpływał na poszczególne cyfry w bardziej zróżnicowany sposób.

Tabela 4.5. Zestawienie metryk podobieństwa dla różnych wartości parametru σ dla zbioru MNIST i metody Occlusion

σ	$\overline{cos}$	SD_{cos}	$\overline{IoU}_K$	SD_{IoU}
0.010	1.000	0.000	0.990	0.006
0.030	1.000	0.000	0.981	0.012
0.050	0.999	0.000	0.967	0.019
0.075	0.998	0.001	0.946	0.029
0.100	0.997	0.002	0.928	0.035
0.150	0.994	0.004	0.902	0.047
0.200	0.990	0.006	0.879	0.055
0.300	0.981	0.011	0.835	0.068
0.500	0.956	0.025	0.755	0.091
0.800	0.890	0.057	0.624	0.128

Ostatnim krokiem była analiza metryki Deletion AUC, której wartości pokazano w tabeli 4.6. Średnia wartość Deletion AUC dla obrazów oryginalnych wynosiła 0,184, natomiast średnia pewność modelu względem klasy docelowej była bardzo wysoka i wynosiła 0,997. Dla obrazów zaszumionych wartości $\overline{AUC}_p$ zmieniały się w niewielkim zakresie. Dla najmniejszego poziomu szumu $\sigma = 0,010$ wartość ta wynosiła 0,185, czyli była praktycznie taka sama jak dla obrazów

oryginalnych. W kolejnych poziomach zakłócenia obserwowano jedynie stopniowy, łagodny spadek tej metryki. Dla $\sigma = 0,300$ średnia wartość $\overline{AUC}_p$ wynosiła 0,172, dla $\sigma = 0,500$ była równa 0,168, a dla największej wartości $\sigma = 0,800$ spadła do 0,158. Dla małych i średnich poziomów szumu obszary wskazywane przez Occlusion zachowywały podobne znaczenie dla decyzji modelu. Przy najwyższym poziomie zakłócenia interpretację należało już uzupełnić o spadek pewności modelu i wzrost liczby zmian predykcji. Było to zgodne z wcześniejszą analizą metryk podobieństwa, która również wskazywała na wysoką stabilność map Occlusion względem szumu Gaussa. Dla małych i średnich wartości σ pewność modelu względem klasy docelowej pozostawała bardzo wysoka. Do poziomu $\sigma = 0,100$ nie odnotowano żadnych zmian predykcji, a średnia pewność dla obrazów zaszumionych nadal wynosiła 0,991. Dopiero przy większych wartościach szumu pojawiły się zmiany klasyfikacji: jedna zmiana dla $\sigma = 0,150$ i $\sigma = 0,200$, dwie dla $\sigma = 0,300$, siedem dla $\sigma = 0,500$ oraz 25 dla $\sigma = 0,800$. Największy poziom zakłócenia wyraźnie wpływał już na działanie modelu klasyfikacyjnego. Dla $\sigma = 0,800$ średnia pewność względem klasy docelowej spadła do 0,708, a liczba zmian predykcji wzrosła do 25.


Tabela 4.6. Wpływ wartości parametru σ szumu Gaussa na metrykę Deletion AUC, pewność predykcji oraz liczbę zmian predykcji dla zbioru MNIST i metody Occlusion

σ	$\overline{AUC}_c$	$SD_{AUC,c}$	$\overline{AUC}_p$	$SD_{AUC,p}$	$\overline{Conf}_c$	$\overline{Conf}_p$	N_{chg}
0.010	0.184	0.263	0.185	0.263	0.997	0.997	0
0.030	0.184	0.263	0.184	0.262	0.997	0.996	0
0.050	0.184	0.263	0.184	0.263	0.997	0.995	0
0.075	0.184	0.263	0.181	0.265	0.997	0.993	0
0.100	0.184	0.263	0.182	0.266	0.997	0.991	0
0.150	0.184	0.263	0.177	0.268	0.997	0.987	1
0.200	0.184	0.263	0.176	0.271	0.997	0.981	1
0.300	0.184	0.263	0.172	0.269	0.997	0.963	2
0.500	0.184	0.263	0.168	0.264	0.997	0.908	7
0.800	0.184	0.263	0.158	0.254	0.997	0.708	25

4.4. Wpływ ataku FGSM na wyjaśnienia generowane metodą Occlusion

Ostatnim eksperymentem przeprowadzanym na zbiorze MNIST była ocena wpływu ataku FGSM na mapy atrybucji generowane przez metodę Occlusion. Porównanie map dla niezaatakowanych obrazów z zaatakowanymi pokazano na rysunku 4.6. Po zastosowaniu ataku FGSM mapy wygenerowane metodą Occlusion uległy wyraźnej degradacji. W wielu przypadkach aktywacje widoczne dla obrazów niezaburzonych zostały silnie osłabione lub niemal całkowicie znikły. Dotyczyło to szczególnie cyfr 0, 1, 2, 3, 5, 6, 7 oraz 9, dla których po perturbacji trudno było wskazać wyraźny region odpowiadający za decyzję modelu. Mapy stawały się bardziej jednorodne, a obszary o wysokiej istotności były znacznie mniej widoczne. Nieco większą stabilność było można zauważyć dla cyfr 4 oraz 8, gdzie po ataku nadal zachowane były

fragmenty odpowiadające pierwotnemu kształtowi znaku. Mimo to również w tych przypadkach intensywność atrybucji była słabsza, a mapa mniej czytelna niż dla obrazu oryginalnego. Oznaczało to, że FGSM nie tylko zmieniała obraz wejściowy, ale silnie wpływała również na sposób, w jaki metoda Occlusion identyfikuje istotne obszary.



Rysunek 4.6. Porównanie map atrybucji Occlusion obrazów niezaatakowanych i zaatakowanych

Przystąpiono do analizy metryk podobieństwa pokazanych w tabeli 4.7. Wyniki wskazywały, że dla niewielkich wartości parametru ϵ metoda zachowywała bardzo wysoką stabilność, jednak wraz ze wzrostem siły ataku zgodność map stopniowo malała.

Dla najmniejszej wartości $\epsilon = 0,010$ średnie podobieństwo cosinusowe wynosiło 0,999, a średnia wartość Top-K IoU 0,963. Oznaczało to, że przy bardzo słabej perturbacji mapy Occlusion były niemal takie same jak dla obrazów oryginalnych, zarówno pod względem ogólnego rozkładu atrybucji, jak i lokalizacji najważniejszych obszarów. Również dla $\epsilon = 0,030$ oraz $\epsilon = 0,050$ wartości obu metryk pozostawały wysokie, co wskazywało na dużą odporność metody przy niskich poziomach ataku. Wraz ze wzrostem wartości ϵ widoczny był jednak systematyczny spadek stabilności. Dla $\epsilon = 0,100$ podobieństwo cosinusowe wynosiło jeszcze 0,959, natomiast Top-K IoU spadło do 0,772. Oznaczało to, że ogólny układ mapy był nadal podobny do mapy dla obrazu oryginalnego, ale lokalizacja najbardziej istotnych regionów zaczęła ulegać wyraźniejszym zmianom. Dla wyższych wartości parametru spadek był znacznie silniejszy. Przy $\epsilon = 0,300$ podobieństwo cosinusowe wynosiło 0,813, a Top-K IoU 0,496, natomiast dla $\epsilon = 0,500$ wartości te spadły odpowiednio do 0,681 oraz 0,337. Odchylenia standardowe rosły wraz ze wzrostem siły ataku, zwłaszcza do wartości $\epsilon = 0,300$. Wskazywało to, że silniejsze perturbacje FGSM wpływały na poszczególne przykłady w bardziej zróżnicowany sposób.

Tabela 4.7. Zestawienie metryk podobieństwa dla różnych wartości parametru ε dla zbioru MNIST i metody Occlusion

ε	$\overline{cos}$	SD_{cos}	$\overline{IoU}_K$	SD_{IoU}
0.010	0.999	0.002	0.963	0.027
0.030	0.994	0.010	0.915	0.058
0.050	0.986	0.021	0.870	0.084
0.075	0.973	0.034	0.819	0.103
0.100	0.959	0.045	0.772	0.117
0.150	0.927	0.067	0.684	0.136
0.200	0.892	0.086	0.612	0.146
0.300	0.813	0.122	0.496	0.153
0.400	0.745	0.125	0.408	0.138
0.500	0.681	0.117	0.337	0.127

W tabeli 4.8 zestawiono wyniki Deletion AUC. Średnia wartość Deletion AUC dla obrazów oryginalnych wynosiła 0,184, natomiast średnia pewność modelu względem klasy docelowej była bardzo wysoka i wynosiła 0,997. Dla obrazów po zastosowaniu FGSM widoczny był stopniowy spadek wartości $\overline{AUC}_p$ wraz ze wzrostem parametru ε . Dla najmniejszej wartości $\varepsilon = 0,010$ średnia wartość Deletion AUC dla obrazów po perturbacji wynosiła 0,179, czyli była zbliżona do wartości uzyskanej dla obrazów oryginalnych. Następnie wartość ta malała, osiągając 0,149 dla $\varepsilon = 0,100$, 0,118 dla $\varepsilon = 0,200$ oraz 0,055 dla największej analizowanej wartości $\varepsilon = 0,500$. Dla niskich wartości ε model zachowywał wysoką pewność względem klasy docelowej, a liczba zmian predykcji była niewielka. Dla $\varepsilon = 0,010$ średnia pewność po perturbacji wynosiła 0,993, a predykcja nie zmieniła się ani razu. Dla $\varepsilon = 0,050$ pewność nadal była wysoka i wynosiła 0,955, przy 4 zmianach predykcji. Wraz ze wzrostem siły ataku FGSM wpływ perturbacji na model stawał się coraz większy. Dla $\varepsilon = 0,150$ średnia pewność spadła do 0,778, a liczba zmian predykcji wzrosła do 18. Dla $\varepsilon = 0,300$ pewność wynosiła już tylko 0,391, przy 56 zmianach predykcji. Przy najwyższych wartościach ε model tracił stabilność klasyfikacji w bardzo dużym stopniu: dla $\varepsilon = 0,400$ odnotowano 74 zmiany predykcji, a dla $\varepsilon = 0,500$ aż 83 zmiany, przy średniej pewności względem klasy docelowej równej 0,167.

Tabela 4.8. Wpływ wartości parametru ε ataku FGSM na metrykę Deletion AUC, pewność predykcji oraz liczbę zmian predykcji dla zbioru MNIST i metody Occlusion

ε	$\overline{AUC}_c$	$SD_{AUC,c}$	$\overline{AUC}_p$	$SD_{AUC,p}$	$\overline{Conf}_c$	$\overline{Conf}_p$	N_{chg}
0.010	0.184	0.263	0.179	0.257	0.997	0.993	0
0.030	0.184	0.263	0.171	0.254	0.997	0.977	2
0.050	0.184	0.263	0.162	0.253	0.997	0.955	4
0.075	0.184	0.263	0.159	0.254	0.997	0.918	7
0.100	0.184	0.263	0.149	0.250	0.997	0.879	9
0.150	0.184	0.263	0.134	0.236	0.997	0.778	18
0.200	0.184	0.263	0.118	0.211	0.997	0.630	33
0.300	0.184	0.263	0.090	0.159	0.997	0.391	56
0.400	0.184	0.263	0.075	0.113	0.997	0.244	74
0.500	0.184	0.263	0.055	0.069	0.997	0.167	83

5. Analiza wyników badań dla zbioru CIFAR-10

W niniejszym rozdziale przedstawiono analizę wyników badań wyjaśnień metodą Integrated Gradients oraz Occlusion dla zbioru CIFAR-10.

5.1. Wpływ szumu Gaussa na wyjaśnienia generowane metodą Integrated Gradients


Tak jak w kroku poprzednim, analizę rozpoczęto od oceny map atrybucji wygenerowanych metodą Integrated Gradients dla niezaburzonych obrazów ze zbioru CIFAR-10. Przykładowe wyniki przedstawiono na rysunku 5.1.



Rysunek 5.1. Mapy atrybucji Integrated Gradients dla obrazów niezaszumionych

W przeciwieństwie do zbioru MNIST, analizowane obrazy miały bardziej złożony charakter: zawierały kolorowe tło, obiekty o mniej regularnych kształtach oraz większą liczbę elementów wizualnych niezwiązanych bezpośrednio z klasą obiektu. Z tego względu mapy atrybucji były mniej jednoznaczne i bardziej rozproszone niż w przypadku cyfr. Dla klasy `airplane` aktywacje były bardziej rozproszone i obejmowały nie tylko obszar samego obiektu, ale również jego otoczenie. W przypadku klasy `automobile` najwyższe wartości atrybucji pojawiały się głównie w rejonie samochodu, przy czym widoczna była także niewielka aktywacja na tle. Podobnie dla klas `bird` oraz `cat` mapy koncentrowały się przede wszystkim w pobliżu analizowanych obiektów, ale zawierały również słabsze aktywacje poza ich bezpośrednim konturem.

Identycznie jak poprzednio, mapy Integrated Gradients dla obrazów niezaburzonych stanowiły punkt odniesienia dla dalszej analizy stabilności. W kolejnym kroku zbadano mapy atrybucji przykładów niezaszumionych z zaszumionymi. Porównanie przedstawiono na rysunku 5.2.



Rysunek 5.2. Mapy atrybucji Integrated Gradients dla obrazów niezaszumionych i zaszumionych

Po dodaniu szumu Gaussa widoczne było przede wszystkim silne osłabienie map atrybucji. Najbardziej czytelna mapa pozostała dla klasy automobile. W tym przypadku nadal widoczne były słabe aktywacje w obszarze zbliżonym do położenia obiektu, chociaż ich intensywność była wyraźnie mniejsza niż dla obrazu oryginalnego. Oznaczało to, że szum Gaussa w znacznym stopniu redukuje siłę atrybucji, ale nie we wszystkich przypadkach prowadził do prawie całkowitego zaniku informacji o obszarach istotnych.

Przystąpiono do zbadania metryk podobieństwa, których wartości pokazano w tabeli 5.1. Wyniki wskazywały na systematyczny spadek zgodności map wraz ze wzrostem wartości parametru σ . Dla najmniejszej wartości zakłócenia $\sigma = 0,010$ średnie podobieństwo cosinusowe wynosiło 0,928, co oznaczało, że ogólny rozkład atrybucji pozostawał jeszcze w dużym stopniu podobny do mapy uzyskanej dla obrazu oryginalnego. Jednocześnie średnia wartość Top-K IoU wynosiła 0,586, a więc zgodność najbardziej istotnych obszarów była wyraźnie niższa niż mogłoby wynikać z samego podobieństwa cosinusowego. Już dla niewielkiego poziomu szumu lokalizacja najważniejszych fragmentów mapy była więc częściowo zaburzona. Wraz ze wzrostem wartości σ obie metryki stopniowo malały. Dla $\sigma = 0,100$ podobieństwo cosinusowe wynosiło 0,743, natomiast Top-K IoU spadło do 0,288. Oznaczało to, że mapa jako całość zachowywała jeszcze pewien stopień podobieństwa do mapy oryginalnej, ale obszary wskazywane jako najważniejsze coraz słabiej pokrywały się z wcześniejszymi atrybucjami. Przy większych wartościach szumu spadek był jeszcze bardziej widoczny. Dla $\sigma = 0,500$ podobieństwo cosinusowe wynosiło 0,576, a Top-K IoU jedynie 0,147, natomiast dla $\sigma = 0,800$ wartości te spadły odpowiednio do 0,529 oraz 0,114. Szczególnie istotna była różnica pomiędzy podobieństwem cosinusowym a Top-K IoU. Podobieństwo cosinusowe malało stopniowo, ale pozostawało na umiarkowanym poziomie nawet dla silniejszych zakłóceń. Top-K IoU spadało natomiast znacznie szybciej, co wskazywało, że szum Gaussa szczególnie mocno wpływał na lokalizację najbardziej istotnych obszarów mapy. Odchylenia standardowe dla podobieństwa cosinusowego pozostawały stosunkowo niewielkie. W przypadku Top-K IoU odchylenia standardowe również pozostawały stosunkowo niewielkie, co sugerowało, że spadek zgodności najważniejszych obszarów występował dość konsekwentnie w analizowanych przykładach.

Tabela 5.1. Zestawienie metryk podobieństwa dla różnych wartości parametru σ dla zbioru CIFAR-10 i metody Integrated Gradients

σ	$\overline{cos}$	SD_{cos}	$\overline{IoU}_K$	SD_{IoU}
0.010	0.928	0.017	0.586	0.056
0.030	0.858	0.030	0.438	0.059
0.050	0.813	0.037	0.371	0.068
0.075	0.771	0.036	0.320	0.064
0.100	0.743	0.041	0.288	0.068
0.150	0.701	0.046	0.246	0.067
0.200	0.673	0.054	0.220	0.067
0.300	0.631	0.060	0.184	0.055
0.500	0.576	0.049	0.147	0.046
0.800	0.529	0.054	0.114	0.038


W tabeli 5.2 przedstawiono wyniki Deletion AUC. Średnia wartość Deletion AUC dla obrazów oryginalnych wynosiła 0,187, natomiast średnia pewność modelu względem klasy docelowej była bardzo wysoka i wynosiła 0,999. Dla obrazów zaburzonych wartości $\overline{AUC}_p$ przy niskich poziomach szumu pozostawały zbliżone do wartości uzyskanej dla obrazów oryginalnych. Dla $\sigma = 0,010$ wartość ta wynosiła 0,195, dla $\sigma = 0,030$ wzrosła do 0,207, a dla $\sigma = 0,050$ ponownie wynosiła 0,195. Oznaczało to, że przy niewielkim zakłóceniu usuwanie pikseli wskazanych przez mapę atrybucji wpływało na model w podobny sposób jak w przypadku obrazów niezaburzonych. Wraz ze wzrostem wartości σ widoczny był jednak stopniowy spadek wartości $\overline{AUC}_p$. Dla $\sigma = 0,150$ wynosiła ona 0,173, dla $\sigma = 0,300$ spadła do 0,161, a dla $\sigma = 0,500$ osiągnęła wartość 0,147. Dla największego poziomu szumu, $\sigma = 0,800$, wartość $\overline{AUC}_p$ wynosiła 0,153, czyli była nieznacznie wyższa niż dla $\sigma = 0,500$, ale nadal niższa od wartości dla obrazów oryginalnych. Należało również uwzględnić spadek pewności modelu oraz liczbę zmian predykcji. Dla małych wartości σ model zachowywał bardzo wysoką pewność. Dla $\sigma = 0,010$ oraz $\sigma = 0,030$ średnia pewność dla obrazów zaburzonych wynosiła odpowiednio 0,999 oraz 0,998, a predykcja nie zmieniła się ani razu. Od $\sigma = 0,050$ zaczęły pojawiać się pojedyncze zmiany predykcji, ale model nadal klasyfikował obrazy z wysoką pewnością. Silniejszy wpływ szumu był widoczny od wartości $\sigma = 0,150$. Średnia pewność modelu spadła wtedy do 0,824, a liczba zmian predykcji wzrosła do 6. Dla $\sigma = 0,200$ pewność obniżyła się już do 0,590, przy 17 zmianach predykcji. Przy najwyższych poziomach szumu model tracił stabilność klasyfikacji w bardzo dużym stopniu: dla $\sigma = 0,500$ średnia pewność wynosiła 0,155, a liczba zmian predykcji osiągnęła 36, natomiast dla $\sigma = 0,800$ pewność spadła do 0,112, przy 39 zmianach predykcji.

Tabela 5.2. Wpływ wartości parametru σ szumu Gaussa na metrykę Deletion AUC, pewność predykcji oraz liczbę zmian predykcji dla zbioru CIFAR-10 i metody Integrated Gradients

σ	$\overline{AUC}_c$	$SD_{AUC,c}$	$\overline{AUC}_p$	$SD_{AUC,p}$	$\overline{Conf}_c$	$\overline{Conf}_p$	N_{chg}
0.010	0.187	0.196	0.195	0.200	0.999	0.999	0
0.030	0.187	0.196	0.207	0.208	0.999	0.998	0
0.050	0.187	0.196	0.195	0.198	0.999	0.985	1
0.075	0.187	0.196	0.186	0.179	0.999	0.975	1
0.100	0.187	0.196	0.194	0.185	0.999	0.959	1
0.150	0.187	0.196	0.173	0.149	0.999	0.824	6
0.200	0.187	0.196	0.168	0.149	0.999	0.590	17
0.300	0.187	0.196	0.161	0.149	0.999	0.411	25
0.500	0.187	0.196	0.147	0.134	0.999	0.155	36
0.800	0.187	0.196	0.153	0.110	0.999	0.112	39

5.2. Wpływ ataku FGSM na wyjaśnienia generowane metodą Integrated Gradients

Kolejnym etapem badań była analiza wpływu ataku FGSM na generowane wyjaśnienia metodą Integrated Gradients. Mapy atrybucji dla wspomnianego ataku pokazano na rysunku 5.3. Po zastosowaniu ataku aktywacje zostały jednak bardzo silnie osłabione. Dla wszystkich analizowanych klas mapy po perturbacji były znacznie mniej czytelne niż mapy dla obrazów oryginalnych. W przypadku klasy airplane można było zauważyć jedynie bardzo słabe pozostałości aktywacji, głównie po prawej stronie obrazu. Dla klas automobile, bird oraz cat mapy po ataku niemal całkowicie zanikały, przez co trudno było wskazać obszary, które metoda uznawała za istotne dla decyzji modelu.



Rysunek 5.3. Mapy atrybucji Integrated Gradients dla obrazów niezaatakowanych i zaatakowanych

Przystąpiono do analizy metryk podobieństwa, których wartości zestawiono w tabeli 5.3. Wyniki wskazywały, że już dla najmniejszej wartości parametru ε zgodność map była wyraźnie ograniczona. Dla $\varepsilon = 0,010$ średnie podobieństwo cosinusowe wynosiło 0,762, natomiast średnia wartość Top-K IoU jedynie 0,305. Oznaczało to, że ogólny układ wartości atrybucji zachowywał jeszcze pewne podobieństwo do mapy dla obrazu oryginalnego, ale obszary

uznawane za najważniejsze pokrywały się już w niewielkim stopniu. Wraz ze wzrostem wartości ϵ obie metryki stopniowo malały. Dla $\epsilon = 0,100$ podobieństwo cosinusowe wynosiło 0,581, a Top-K IoU spadło do 0,133. Przy największej analizowanej wartości $\epsilon = 0,500$ średnie podobieństwo cosinusowe osiągnęło wartość 0,507, natomiast Top-K IoU wyniosło jedynie 0,088. Oznaczało to, że dla silnego ataku FGSM mapy po perturbacji bardzo słabo pokrywały się z mapami uzyskanymi dla obrazów oryginalnych, szczególnie w zakresie najbardziej istotnych pikseli. Istotna była różnica pomiędzy wartościami podobieństwa cosinusowego i Top-K IoU. Podobieństwo cosinusowe pozostawało na umiarkowanym poziomie nawet dla dużych wartości ϵ . W przypadku map po ataku FGSM widoczne było silne osłabienie sygnału atrybucji, jednak pewne zależności przestrzenne mogły nadal pozostawać zachowane. Z kolei bardzo niskie wartości Top-K IoU pokazywały, że najważniejsze obszary mapy po perturbacji w niewielkim stopniu pokrywały się z obszarami wskazywanymi dla obrazów niezaburzonych. Odchylenia standardowe dla podobieństwa cosinusowego utrzymywały się na zbliżonym poziomie, od 0,047 do 0,062, co wskazywało na dość konsekwentny wpływ ataku w analizowanych przykładach. W przypadku Top-K IoU odchylenia standardowe również były niewielkie i malały dla większych wartości ϵ , co sugerowało, że przy silniejszych perturbacjach spadek zgodności najważniejszych obszarów był podobny dla większości analizowanych obrazów.

Tabela 5.3. Zestawienie metryk podobieństwa dla różnych wartości parametru ϵ dla zbioru CIFAR-10 i metody Integrated Gradients

ϵ	$\overline{cos}$	SD_{cos}	$\overline{IoU}_K$	SD_{IoU}
0.010	0.762	0.062	0.305	0.079
0.030	0.654	0.053	0.191	0.059
0.050	0.617	0.055	0.160	0.053
0.075	0.593	0.055	0.141	0.045
0.100	0.581	0.059	0.133	0.043
0.150	0.560	0.057	0.120	0.049
0.200	0.549	0.059	0.114	0.055
0.300	0.535	0.056	0.104	0.051
0.400	0.520	0.050	0.095	0.045
0.500	0.507	0.047	0.088	0.038

Wyniki Deletion AUC zaprezentowano w tabeli 5.4. Średnia wartość Deletion AUC dla obrazów oryginalnych wynosiła 0,185, a średnia pewność modelu względem klasy docelowej była bardzo wysoka i wynosiła 0,999. Dla obrazów po zastosowaniu FGSM widoczny był spadek wartości $\overline{AUC}_p$ względem obrazów oryginalnych. Już dla najmniejszej wartości $\epsilon = 0,010$ średnia wartość Deletion AUC dla obrazów po perturbacji wynosiła 0,145, a następnie wykazywała ogólny trend spadkowy wraz ze wzrostem siły ataku. Dla $\epsilon = 0,200$ osiągnęła wartość 0,117, dla $\epsilon = 0,300$ spadła do 0,100, natomiast dla największej analizowanej wartości $\epsilon = 0,500$ wyniosła jedynie 0,070. Atak FGSM bardzo silnie wpływał na decyzje modelu już dla najmniejszych wartości parametru ϵ . Dla $\epsilon = 0,010$ średnia pewność względem klasy docelowej

spadła z 0,999 do 0,281, a predykcja zmieniła się w 29 przypadkach. Dla $\varepsilon = 0,030$ pewność wynosiła już tylko 0,094, przy 37 zmianach predykcji. Oznaczało to, że nawet bardzo niewielka perturbacja FGSM znacząco zaburzała klasyfikację obrazów CIFAR-10. Dla kolejnych wartości ε liczba zmian predykcji pozostawała bardzo wysoka. Przy $\varepsilon = 0,075$ zmieniły się wszystkie analizowane predykcje, a średnia pewność modelu względem klasy docelowej spadła do 0,026. Dla większych wartości ε pewność względem klasy docelowej częściowo wzrastała, osiągając 0,230 dla $\varepsilon = 0,500$, jednak nadal pozostawała znacznie niższa niż dla obrazów oryginalnych. Warto zauważyć, że liczba zmian predykcji nie rosła monotonicznie wraz ze wzrostem wartości ε . Największą liczbę zmian odnotowano dla $\varepsilon = 0,075$, gdzie zmieniły się wszystkie analizowane predykcje, natomiast dla największych wartości parametru liczba zmian była niższa.

Tabela 5.4. Wpływ wartości parametru ε ataku FGSM na metrykę Deletion AUC, pewność predykcji oraz liczbę zmian predykcji dla zbioru CIFAR-10 i metody Integrated Gradients

ε	$\overline{AUC}_c$	$SD_{AUC,c}$	$\overline{AUC}_p$	$SD_{AUC,p}$	$\overline{Conf}_c$	$\overline{Conf}_p$	N_{chg}
0.010	0.185	0.195	0.145	0.165	0.999	0.281	29
0.030	0.185	0.195	0.146	0.146	0.999	0.094	37
0.050	0.185	0.195	0.144	0.145	0.999	0.064	37
0.075	0.185	0.195	0.144	0.145	0.999	0.026	40
0.100	0.185	0.195	0.136	0.130	0.999	0.033	39
0.150	0.185	0.195	0.126	0.125	0.999	0.078	38
0.200	0.185	0.195	0.117	0.105	0.999	0.118	38
0.300	0.185	0.195	0.100	0.096	0.999	0.176	33
0.400	0.185	0.195	0.085	0.079	0.999	0.211	30
0.500	0.185	0.195	0.070	0.069	0.999	0.230	30

5.3. Wpływ szumu Gaussa na wyjaśnienia generowane metodą Occlusion


Kolejny etap eksperymentów odnosił się do badania wyjaśnień generowanych metodą Occlusion. Na rysunku 5.4 pokazano przykładowe mapy atrybucji dla przykładów niezaburzonych.



Rysunek 5.4. Mapy atrybucji Occlusion dla obrazów niezaszumionych

W przypadku klasy airplane najwyższe wartości atrybucji pojawiały się przede wszystkim w obszarze nieba oraz w otoczeniu samolotu, a nie wyłącznie na samym obiekcie. Mogło to wskazywać, że model przy klasyfikacji tej próbki wykorzystywał również kontekst sceny, charakterystyczny dla obrazów przedstawiających samoloty. Dla klasy automobile aktywacje były widoczne głównie w pobliżu samochodu, ale obejmowały także fragmenty dolnej części obrazu. W przypadku klasy bird mapa wskazywała kilka obszarów istotnych, częściowo związanych z sylwetką ptaka oraz jego otoczeniem. Dla klasy cat najwyższe wartości atrybucji występowały głównie po prawej stronie obrazu, w obszarze odpowiadającym położeniu zwierzęcia.

Przystąpiono do badania map atrybucji dla obrazów niezaszumionych i zaszumionych, które pokazano na rysunku 5.5. Po dodaniu szumu Gaussa mapy Occlusion zachowały część struktury widocznej dla obrazów oryginalnych, jednak w większości przypadków aktywacje stały się słabsze i mniej jednoznaczne. Dla klasy airplane na mapie po perturbacji nadal widoczne były obszary istotne w podobnym rejonie obrazu, ale ich intensywność była mniejsza niż dla obrazu niezaburzonego. W przypadku klasy automobile aktywacje pozostały stosunkowo czytelne i nadal koncentrowały się w pobliżu obszaru samochodu. Dla klasy bird po dodaniu szumu mapa stała się mniej spójna. Część wcześniejszych silnych aktywacji została osłabiona, a obszary istotne były trudniejsze do jednoznacznego powiązania z sylwetką obiektu. W przypadku klasy cat mapa po perturbacji również zachowała pewne aktywacje w obszarze obiektu, jednak były one mniej skoncentrowane niż dla obrazu oryginalnego.



Rysunek 5.5. Mapy atrybucji Occlusion dla obrazów niezaszumionych i zaszumionych

Metryki podobieństwa pokazano w tabeli 5.5. Wyniki wskazywały, że dla niewielkich wartości parametru σ mapy pozostawały bardzo stabilne, natomiast wraz ze wzrostem poziomu szumu ich zgodność stopniowo malała. Dla najmniejszej wartości $\sigma = 0,010$ średnie podobieństwo cosinusowe wynosiło 1,000, a średnia wartość Top-K IoU 0,971. Oznaczało to niemal pełną zgodność map Occlusion przed i po dodaniu bardzo słabego szumu. Również dla $\sigma = 0,030$ oraz $\sigma = 0,050$ wartości metryk pozostawały wysokie, co wskazywało, że niskie poziomy zakłócenia nie zaburzały znacząco położenia najważniejszych obszarów. Wraz ze wzrostem wartości σ spadek podobieństwa stawał się coraz bardziej widoczny. Dla $\sigma = 0,100$

podobieństwo cosinusowe wynosiło 0,949, natomiast Top-K IoU spadło do 0,636. Oznaczało to, że ogólny układ mapy nadal był podobny do mapy dla obrazu oryginalnego, ale lokalizacja najbardziej istotnych regionów zaczęła zmieniać się wyraźniej. Dla większych wartości szumu różnica była jeszcze silniejsza. Przy $\sigma = 0,300$ podobieństwo cosinusowe wynosiło 0,802, a Top-K IoU 0,336, natomiast dla $\sigma = 0,800$ wartości te spadły odpowiednio do 0,676 oraz 0,152. Wyniki pokazywały również, że Top-K IoU malało szybciej niż podobieństwo cosinusowe. Sugerowało to, że metoda Occlusion przez dłuższy czas zachowywała ogólny kształt lub rozkład mapy, ale dokładne położenie najważniejszych regionów stawało się coraz mniej stabilne. Odchylenia standardowe rosły wraz ze wzrostem wartości σ w przypadku podobieństwa cosinusowego. Dla Top-K IoU odchylenia standardowe rosły przede wszystkim do średnich poziomów szumu, a następnie częściowo malały. Wskazywało to, że największe zróżnicowanie wpływu szumu występowało dla wartości pośrednich. Oznaczało to, że silniejszy szum wpływał na poszczególne przykłady w bardziej zróżnicowany sposób. Dla części obrazów mapy mogły zachowywać większą zgodność z mapami oryginalnymi, natomiast dla innych zmiany położenia istotnych regionów były wyraźniejsze.

Tabela 5.5. Zestawienie metryk podobieństwa dla różnych wartości parametru σ dla zbioru CIFAR-10 i metody Occlusion

σ	$\overline{cos}$	SD_{cos}	$\overline{IoU}_K$	SD_{IoU}
0.010	1.000	0.000	0.971	0.016
0.030	0.998	0.001	0.907	0.040
0.050	0.991	0.007	0.827	0.078
0.075	0.975	0.025	0.716	0.139
0.100	0.949	0.048	0.636	0.175
0.150	0.904	0.081	0.512	0.196
0.200	0.858	0.093	0.416	0.195
0.300	0.802	0.097	0.336	0.176
0.500	0.719	0.101	0.223	0.147
0.800	0.676	0.105	0.152	0.122

Wyniki Deletion AUC zestawiono w tabeli 5.6. Średnia wartość Deletion AUC dla obrazów oryginalnych wynosiła 0,278, a średnia pewność modelu względem klasy docelowej wynosiła 0,999. Dla niskich poziomów szumu wartości $\overline{AUC}_p$ pozostawały zbliżone do wartości uzyskanej dla obrazów oryginalnych. Dla $\sigma = 0,010$ wynosiła ona 0,277, dla $\sigma = 0,030$ 0,275, a dla $\sigma = 0,050$ 0,281. Oznaczało to, że przy niewielkim zakłóceniu usuwanie obszarów wskazanych przez mapę Occlusion wpływało na model w podobny sposób jak w przypadku obrazów niezaburzonych. Dla większych wartości σ widoczny był jednak spadek wartości $\overline{AUC}_p$, chociaż nie miał on całkowicie monotonicznego charakteru. Dla $\sigma = 0,150$ średnia wartość Deletion AUC wynosiła 0,250, dla $\sigma = 0,200$ spadła do 0,238, a dla $\sigma = 0,300$ osiągnęła wartość 0,165. Przy najwyższych poziomach zakłócenia wartości pozostawały już wyraźnie niższe niż dla obrazów oryginalnych i wynosiły 0,182 dla $\sigma = 0,500$ oraz 0,177 dla $\sigma = 0,800$. Dla małych wartości


σ model zachowywał bardzo wysoką pewność względem klasy docelowej. Do $\sigma = 0,050$ nie odnotowano żadnych zmian predykcji, a średnia pewność dla obrazów zaburzonych utrzymywała się na poziomie od 0,990 do 0,999. Pierwsze zmiany pojawiły się dla $\sigma = 0,075$ oraz $\sigma = 0,100$, gdzie odnotowano po jednej zmianie predykcji. Wyraźniejsze pogorszenie stabilności klasyfikacji nastąpiło dla większych poziomów szumu. Dla $\sigma = 0,150$ średnia pewność modelu spadła do 0,755, a liczba zmian predykcji wzrosła do 10. Dla $\sigma = 0,300$ pewność obniżyła się do 0,386, przy 26 zmianach predykcji. Przy najsilniejszych zakłóceniach model klasyfikował obrazy znacznie mniej stabilnie: dla $\sigma = 0,500$ średnia pewność wynosiła 0,131, a liczba zmian predykcji osiągnęła 36, natomiast dla $\sigma = 0,800$ pewność spadła do 0,112, przy 39 zmianach predykcji.

Tabela 5.6. Wpływ wartości parametru σ szumu Gaussa na metrykę Deletion AUC, pewność predykcji oraz liczbę zmian predykcji dla zbioru CIFAR-10 i metody Occlusion

σ	$\overline{AUC}_c$	$SD_{AUC,c}$	$\overline{AUC}_p$	$SD_{AUC,p}$	$\overline{Conf}_c$	$\overline{Conf}_p$	N_{chg}
0.010	0.278	0.211	0.277	0.215	0.999	0.999	0
0.030	0.278	0.211	0.275	0.209	0.999	0.999	0
0.050	0.278	0.211	0.281	0.225	0.999	0.990	0
0.075	0.278	0.211	0.271	0.204	0.999	0.975	1
0.100	0.278	0.211	0.298	0.214	0.999	0.963	1
0.150	0.278	0.211	0.250	0.183	0.999	0.755	10
0.200	0.278	0.211	0.238	0.165	0.999	0.627	14
0.300	0.278	0.211	0.165	0.140	0.999	0.386	26
0.500	0.278	0.211	0.182	0.158	0.999	0.131	36
0.800	0.278	0.211	0.177	0.197	0.999	0.112	39

5.4. Wpływ ataku FGSM na wyjaśnienia generowane metodą Occlusion

Przystąpiono do ostatniego eksperymentu w przeprowadzonych badaniach. Na rysunku 5.6 przedstawiono mapy atrybucji dla obrazów niezaatakowanych oraz zaatakowanych.



Rysunek 5.6. Mapy atrybucji Occlusion dla obrazów niezaatakowanych i zaatakowanych

Po zastosowaniu ataku FGSM mapy Occlusion uległy wyraźnym zmianom względem map dla obrazów oryginalnych. W przypadku klasy *airplane* istotne obszary nie znikły całkowicie, ale ich rozmieszczenie zmieniło się i stało się mniej zgodne z mapą dla obrazu niezaburzonego. Dla klasy *automobile* po perturbacji nadal widoczny był wyraźny obszar aktywacji w rejonie samochodu, jednak pozostała część mapy była słabsza i mniej rozbudowana niż wcześniej. Największe zmiany były widoczne dla klas *bird* oraz *cat*. W przypadku klasy *bird* mapa po ataku stała się bardziej chaotyczna, a wysokie wartości atrybucji pojawiały się w wielu miejscach obrazu, przez co trudniej było jednoznacznie powiązać je z konkretnym fragmentem obiektu. Dla klasy *cat* aktywacje po perturbacji zostały wyraźnie osłabione i ograniczone do mniejszych obszarów, przez co mapa była mniej czytelna niż dla obrazu oryginalnego.

W tabeli 5.7 pokazano wartości metryk podobieństwa. Wyniki wskazywały, że perturbacja adversarialna wyraźnie wpływała na stabilność map już dla najmniejszych wartości parametru ϵ . Dla $\epsilon = 0,010$ średnie podobieństwo cosinusowe wynosiło 0,791, natomiast średnia wartość Top-K IoU była równa 0,339. Oznaczało to, że ogólny rozkład map Occlusion zachowywał jeszcze umiarkowane podobieństwo do map dla obrazów oryginalnych, ale zgodność najbardziej istotnych obszarów była już stosunkowo niska. Innymi słowy, nawet niewielka perturbacja FGSM powodowała zmianę lokalizacji regionów uznawanych przez metodę za kluczowe. Wraz ze wzrostem wartości ϵ obie metryki stopniowo malały. Dla $\epsilon = 0,100$ podobieństwo cosinusowe wynosiło 0,679, a Top-K IoU spadło do 0,180. Przy większych wartościach ataku spadek był jeszcze bardziej widoczny. Dla $\epsilon = 0,300$ podobieństwo cosinusowe wynosiło 0,578, a Top-K IoU 0,114, natomiast dla $\epsilon = 0,500$ wartości te wynosiły odpowiednio 0,567 (delikatny wzrost względem $\epsilon = 0,400$, gdzie podobieństwo cosinusowe wynosiło 0,558) oraz 0,079. Szczególnie istotne były bardzo niskie wartości Top-K IoU. Pokazywały one, że obszary o najwyższej atrybucji po zastosowaniu FGSM w niewielkim stopniu pokrywały się z obszarami wskazywanymi dla obrazów oryginalnych. Podobieństwo cosinusowe pozostawało na poziomie umiarkowanym, co sugerowało, że pewna ogólna struktura map mogła być jeszcze częściowo zachowana. Jednak metryka Top-K IoU wskazywała, że dokładna lokalizacja najważniejszych regionów była silnie zaburzona. Odchylenia standardowe, zwłaszcza dla Top-K IoU przy małych wartościach ϵ , były relatywnie wysokie. Dla $\epsilon = 0,010$ odchylenie standardowe Top-K IoU wynosiło 0,234, co oznaczało, że wpływ ataku był zróżnicowany pomiędzy analizowanymi przykładami. Dla części obrazów najważniejsze obszary mogły zachowywać większą zgodność, natomiast dla innych zmieniały się znacznie silniej. Wraz ze wzrostem ϵ odchylenia standardowe, zwłaszcza dla Top-K IoU, wykazywały ogólną tendencję spadkową, choć w przypadku podobieństwa cosinusowego nie był to przebieg ściśle monotoniczny.

Tabela 5.7. Zestawienie metryk podobieństwa dla różnych wartości parametru ε dla zbioru CIFAR-10 i metody Occlusion

ε	$\overline{cos}$	SD_{cos}	$\overline{IoU}_K$	SD_{IoU}
0.010	0.791	0.131	0.339	0.234
0.030	0.715	0.126	0.224	0.186
0.050	0.702	0.106	0.204	0.160
0.075	0.688	0.108	0.192	0.144
0.100	0.679	0.110	0.180	0.138
0.150	0.661	0.113	0.168	0.136
0.200	0.631	0.110	0.144	0.121
0.300	0.578	0.094	0.114	0.100
0.400	0.558	0.085	0.092	0.080
0.500	0.567	0.089	0.079	0.069

Metrykę Deletion AUC pokazano w tabeli 5.8. Średnia wartość Deletion AUC dla obrazów oryginalnych wynosiła 0,278, natomiast średnia pewność modelu względem klasy docelowej wynosiła 0,999. Dla obrazów po zastosowaniu ataku FGSM wartości $\overline{AUC}_p$ były niższe niż dla obrazów oryginalnych. Już dla najmniejszej wartości $\varepsilon = 0,010$ średnia wartość Deletion AUC dla obrazów po perturbacji wynosiła 0,152, co wskazywało na wyraźną zmianę względem map uzyskanych dla obrazów niezaburzonych. Dla kolejnych wartości ε metryka nie zmieniała się całkowicie monotonicznie, ale pozostawała wyraźnie poniżej wartości $\overline{AUC}_c$. Najniższe wartości uzyskano dla $\varepsilon = 0,400$, gdzie $\overline{AUC}_p$ wynosiło 0,103, oraz dla $\varepsilon = 0,500$, gdzie spadło do 0,085. Atak FGSM bardzo silnie wpływał na decyzje modelu już dla najmniejszej wartości parametru. Dla $\varepsilon = 0,010$ średnia pewność modelu względem klasy docelowej spadła z 0,999 do 0,281, a predykcja zmieniła się w 29 przypadkach. Dla $\varepsilon = 0,030$ pewność wynosiła już tylko 0,094, przy 37 zmianach predykcji. Dla wartości $\varepsilon = 0,075$ liczba zmian predykcji osiągnęła 40, czyli obejmowała wszystkie analizowane przykłady. Średnia pewność względem klasy docelowej wynosiła wtedy jedynie 0,026. Przy dalszym wzroście ε liczba zmian predykcji pozostawała bardzo wysoka, choć nieco malała dla największych wartości parametru. Dla $\varepsilon = 0,400$ oraz $\varepsilon = 0,500$ odnotowano po 30 zmian predykcji, a średnia pewność względem klasy docelowej wynosiła odpowiednio 0,211 oraz 0,230.

Tabela 5.8. Wpływ wartości parametru ε ataku FGSM na metrykę Deletion AUC, pewność predykcji oraz liczbę zmian predykcji dla zbioru CIFAR-10 i metody Occlusion

ε	$\overline{AUC}_c$	$SD_{AUC,c}$	$\overline{AUC}_p$	$SD_{AUC,p}$	$\overline{Conf}_c$	$\overline{Conf}_p$	N_{chg}
0.010	0.278	0.211	0.152	0.159	0.999	0.281	29
0.030	0.278	0.211	0.119	0.126	0.999	0.094	37
0.050	0.278	0.211	0.118	0.114	0.999	0.064	37
0.075	0.278	0.211	0.109	0.094	0.999	0.026	40
0.100	0.278	0.211	0.125	0.135	0.999	0.033	39
0.150	0.278	0.211	0.180	0.187	0.999	0.078	38
0.200	0.278	0.211	0.190	0.198	0.999	0.118	38
0.300	0.278	0.211	0.153	0.166	0.999	0.176	33
0.400	0.278	0.211	0.103	0.104	0.999	0.211	30
0.500	0.278	0.211	0.085	0.086	0.999	0.230	30

6. Analiza porównawcza wyników

Zestawione wyniki pozwoliły porównać stabilność wyjaśnień generowanych metodami Integrated Gradients oraz Occlusion dla dwóch zbiorów danych: MNIST oraz CIFAR-10. Analiza obejmowała dwa typy perturbacji, czyli szum Gaussa oraz atak FGSM. Oba zakłócenia miały odmienny charakter, dlatego ich wpływ na mapy atrybucji oraz wyniki modelu należało interpretować w różny sposób. Szum Gaussa był perturbacją losową, niezależną od modelu, polegającą na dodaniu przypadkowych zmian do wartości pikseli. FGSM był natomiast perturbacją ukierunkowaną, wyznaczaną na podstawie gradientu funkcji straty względem obrazu wejściowego. Oznaczało to, że atak ten był bezpośrednio związany z mechanizmem decyzyjnym modelu i mógł silniej wpływać zarówno na predykcję, jak i na generowane wyjaśnienia. Warto podkreślić, że najwyższe wartości parametrów perturbacji, wykorzystywane zarówno w wizualizacjach, jak i w kilku ostatnich punktach analizy ilościowej, pełniły przede wszystkim rolę testu obciążeniowego. Ich celem nie było odtworzenie typowych zakłóceń występujących w danych wejściowych, lecz sprawdzenie, jak model oraz metody wyjaśniania zachowywały się w warunkach silnego zaburzenia obrazu. Z tego względu wyniki dla największych wartości σ oraz ϵ należało interpretować ostrożnie. Były one szczególnie przydatne do oceny granic stabilności metod XAI, ale często dotyczyły już sytuacji, w której zmieniały się nie tylko mapy atrybucji, lecz także pewność modelu lub sama predykcja. Istotne znaczenie miała również różnica pomiędzy analizowanymi zbiorami danych. Obrazy MNIST miały prostą strukturę, zawierały pojedynczą cyfrę na jednorodnym tle, a informacja istotna dla klasyfikacji była skupiona głównie w obrębie kształtu znaku. CIFAR-10 zawierał natomiast obrazy naturalne, kolorowe, z bardziej złożonym tłem i większą liczbą szczegółów wizualnych. W konsekwencji mapy atrybucji dla CIFAR-10 były trudniejsze do interpretacji, ponieważ model mógł wykorzystywać nie tylko fragmenty samego obiektu, ale również elementy jego otoczenia oraz kontekst sceny.

Do oceny stabilności wyjaśnień wykorzystano kilka uzupełniających się miar. Podobieństwo cosinusowe pozwalało ocenić globalną zgodność rozkładu wartości atrybucji pomiędzy mapą dla obrazu oryginalnego i mapą dla obrazu zaburzonego. Ponieważ metryka ta porównywała mapy po spłaszczeniu do postaci wektorów, była mniej wrażliwa na samą skalę wartości. Oznaczało to, że mapa wizualnie osłabiona mogła nadal uzyskać umiarkowane podobieństwo cosinusowe, jeśli zachowywała podobny względny układ wartości. Top-K IoU miało bardziej lokalny i restrykcyjny charakter, ponieważ porównywało zbiory pikseli o najwyższych wartościach atrybucji. Spadek tej metryki oznaczał więc, że po perturbacji zmieniało się położenie regionów uznawanych przez metodę za najważniejsze. Trzecim elementem analizy była metryka Deletion AUC. W przeciwieństwie do podobieństwa cosinusowego i Top-K IoU nie mierzyła ona bezpośrednio podobieństwa dwóch map. Sprawdzała natomiast, jak stopniowe usuwanie pikseli wskazanych przez mapę atrybucji wpływało na pewność modelu względem klasy docelowej. Niższa wartość Deletion AUC mogła oznaczać, że usuwane piksele rzeczywiście były istotne dla predykcji,

ponieważ ich zastępowanie wartością bazową szybko obniżało pewność modelu. Interpretacja tej metryki wymagała jednak uwzględnienia średniej pewności modelu oraz liczby zmian predykcji. Jeżeli model już przed rozpoczęciem procedury usuwania miał niską pewność względem klasy docelowej albo zmieniał predykcję, to niska wartość Deletion AUC nie musiała świadczyć wyłącznie o jakości mapy. Mogła częściowo wynikać z tego, że klasyfikacja była już silnie zaburzona przez samą perturbację.

W przypadku zbioru MNIST i szumu Gaussa metoda Integrated Gradients wykazywała stopniowy spadek stabilności wraz ze wzrostem wartości σ . Podobieństwo cosinusowe zmniejszyło się z 0,901 dla $\sigma = 0,010$ do 0,598 dla $\sigma = 0,800$, natomiast Top-K IoU spadło z 0,764 do 0,400. Oznaczało to, że ogólny rozkład map atrybucji pozostawał częściowo podobny, ale położenie najbardziej istotnych pikseli zmieniało się coraz wyraźniej. Było to zgodne z charakterem Integrated Gradients, ponieważ metoda ta opierała się na gradientach wyznaczanych wzdłuż ścieżki od obrazu bazowego do obrazu wejściowego. Dodanie szumu wpływało na lokalną strukturę obrazu i zmieniało wartości gradientów, a w konsekwencji również rozkład atrybucji. Wyniki Deletion AUC dla tego samego eksperymentu pokazały inny aspekt zmian. Dla obrazów niezaburzonych średnia wartość $\overline{AUC}_c$ wynosiła 0,279, natomiast dla obrazów zaburzonych $\overline{AUC}_p$ początkowo była wyższa i dla $\sigma = 0,010$ wynosiła 0,411. Nie oznaczało to poprawy map po perturbacji. Wyższa wartość Deletion AUC wskazywała raczej, że piksele wskazane przez mapę IG dla obrazu zaburzonego były mniej skuteczne w obniżaniu pewności modelu niż piksele wskazane dla obrazu oryginalnego. Innymi słowy, po niewielkim zaszumieniu mapa mogła nadal wyglądać częściowo podobnie do mapy czystej, ale jej funkcjonalna skuteczność w procedurze deletion była słabsza. Wraz ze wzrostem poziomu szumu $\overline{AUC}_p$ zaczęło maleć i dla $\sigma = 0,800$ osiągnęło 0,104. Ten końcowy spadek należało jednak interpretować łącznie z pewnością modelu, która dla największego szumu zmniejszyła się do 0,703, oraz z liczbą zmian predykcji równą 24. Przy tak silnym zakłóceniu niska wartość AUC wynikała więc nie tylko z mapy atrybucji, ale także z osłabienia samej klasyfikacji.

W przypadku Occlusion dla MNIST szum Gaussa miał znacznie słabszy wpływ na metryki podobieństwa. Podobieństwo cosinusowe utrzymywało się na bardzo wysokim poziomie i nawet dla $\sigma = 0,800$ wynosiło 0,890, natomiast Top-K IoU spadło do 0,624. Były to wartości wyraźnie wyższe niż dla Integrated Gradients. Wynikało to z regionalnego charakteru Occlusion. Metoda ta oceniała wpływ zasłaniania większych fragmentów obrazu, a nie bezpośrednio lokalne gradienty pojedynczych pikseli. W przypadku prostych obrazów MNIST takie podejście było mniej podatne na drobne, losowe zmiany wartości pikseli, ponieważ najważniejsze regiony nadal pozostawały związane z kształtem cyfry. Deletion AUC również potwierdzało stabilniejszy charakter Occlusion dla szumu Gaussa na MNIST. Dla obrazów czystych $\overline{AUC}_c$ wynosiło 0,184, a dla obrazów zaburzonych wartości $\overline{AUC}_p$ przez większość zakresu parametru σ pozostawały bardzo blisko tej wartości. Dla $\sigma = 0,010$ wynosiły 0,185, a dla $\sigma = 0,800$ spadły tylko do 0,158. Oznaczało to, że skuteczność regionów wskazywanych przez Occlusion w procedurze deletion zmieniała się powoli. Było to zgodne z tym, że metoda działała na większych obszarach

i nie reagowała tak silnie na pojedyncze zakłócone piksele. Dopiero przy najwyższym poziomie szumu interpretację należało uzupełnić o informację o spadku pewności modelu do 0,708 i 25 zmianach predykcji.

Dla zbioru CIFAR-10 przy szumie Gaussa wyniki Integrated Gradients były częściowo zbliżone do MNIST, jeśli analizowano samo podobieństwo cosinusowe. Spadło ono z 0,928 dla $\sigma = 0,010$ do 0,529 dla $\sigma = 0,800$. Nie można było więc jednoznacznie stwierdzić, że szum Gaussa globalnie wpływał na CIFAR-10 znacznie silniej niż na MNIST. Różnica była jednak wyraźniejsza w metryce Top-K IoU. Dla CIFAR-10 wartość ta spadła z 0,586 do 0,114, podczas gdy dla MNIST przy największym szumie wynosiła 0,400. Oznaczało to, że losowa perturbacja szczególnie silnie zaburzała położenie najbardziej istotnych regionów w obrazach naturalnych, nawet jeśli globalny rozkład atrybucji zachowywał jeszcze umiarkowane podobieństwo. Deletion AUC dla Integrated Gradients na CIFAR-10 pokazało, że dla małych wartości σ mapy po perturbacji nadal można było interpretować przy stosunkowo stabilnej klasyfikacji. Średnia wartość $\overline{AUC}_c$ wynosiła 0,187, a wartości $\overline{AUC}_p$ dla niewielkiego szumu pozostawały blisko tego poziomu. Dla $\sigma = 0,030$ wynosiły nawet 0,207, co oznaczało niewielki wzrost względem obrazów czystych. Podobnie jak w przypadku MNIST nie należało traktować tego jako poprawy wyjaśnień, lecz jako sygnał, że mapa po perturbacji mogła wskazywać piksele mniej skuteczne w szybkim obniżaniu pewności modelu. Przy większych poziomach szumu wartości AUC zaczęły się obniżać, ale równocześnie spadała pewność modelu. Dla $\sigma = 0,200$ średnia pewność względem klasy docelowej wynosiła 0,590, a liczba zmian predykcji wzrosła do 17. Dla $\sigma = 0,800$ pewność spadła do 0,112, a predykcja zmieniła się w 39 przypadkach. W tych punktach wynik Deletion AUC odzwierciedlał więc nie tylko zmianę jakości map, ale także silne zaburzenie decyzji modelu.

W przypadku Occlusion na CIFAR-10 szum Gaussa również powodował spadek stabilności, ale podobieństwo cosinusowe było wyższe niż dla Integrated Gradients. Dla $\sigma = 0,800$ wynosiło 0,676, natomiast Top-K IoU spadło do 0,152. Oznaczało to, że regionalna struktura map Occlusion była bardziej odporna globalnie, ale położenie najważniejszych regionów i tak zmieniał się wyraźnie. W obrazach CIFAR-10 istotne informacje mogły być rozłożone pomiędzy obiektem, tłem i kontekstem sceny, dlatego nawet metoda oparta na zasłanianiu większych obszarów była podatna na przesunięcie lub osłabienie regionów uznawanych za kluczowe. Deletion AUC dla Occlusion na CIFAR-10 wskazywało na inną zależność niż dla MNIST. Dla obrazów czystych $\overline{AUC}_c$ wynosiło 0,278, czyli było wyższe niż dla Integrated Gradients. Ponieważ niższa wartość Deletion AUC oznaczała szybszy spadek pewności po usunięciu istotnych pikseli, wynik ten sugerował, że dla czystych obrazów CIFAR-10 mapy Integrated Gradients były bardziej skuteczne w procedurze deletion. Occlusion zachowywała większą stabilność przestrzenną, ale jej szersze, regionalne mapy nie zawsze prowadziły do równie szybkiego spadku pewności modelu. Dla obrazów zaszumionych wartości $\overline{AUC}_p$ początkowo pozostawały blisko wartości dla obrazów czystych, a dla $\sigma = 0,100$ wzrosły do 0,298. Następnie przy większych poziomach szumu malały, osiągając 0,177 dla $\sigma = 0,800$. Tego wzrostu przy

średnim poziomie szumu nie należało traktować jako poprawy jakości mapy, lecz jako efekt zmiany sposobu, w jaki mapa Occlusion wskazywała regiony istotne po perturbacji. Przy największych wartościach σ interpretacja Deletion AUC była dodatkowo ograniczona przez wyraźny spadek pewności modelu i dużą liczbę zmian predykcji.

Porównanie wyników dla szumu Gaussa pokazało więc, że Occlusion była bardziej stabilna przestrzennie od Integrated Gradients w obu zbiorach danych. Było to szczególnie widoczne w podobieństwie cosinusowym, a w wielu przypadkach także w Top-K IoU. Jednocześnie Deletion AUC pokazało, że większa stabilność przestrzenna nie zawsze oznaczała większą skuteczność wskazywania pikseli krytycznych dla predykcji. Dla MNIST Occlusion uzyskiwała niższe AUC dla obrazów czystych niż IG, natomiast dla CIFAR-10 zależność była odwrotna i korzystniejsze wartości AUC uzyskiwało Integrated Gradients.

W przypadku ataku FGSM zależności były bardziej gwałtowne. Dla MNIST metoda Integrated Gradients traciła stabilność stopniowo wraz ze wzrostem wartości ϵ . Podobieństwo cosinusowe spadło z 0,853 dla $\epsilon = 0,010$ do 0,541 dla $\epsilon = 0,500$, a Top-K IoU z 0,707 do 0,390. W porównaniu ze szumem Gaussa wartości te były niższe już przy małych poziomach perturbacji, co było zgodne z naturą FGSM. Atak ten nie dodawał losowego szumu, lecz modyfikował obraz w kierunku zwiększającym stratę modelu. Ponieważ Integrated Gradients również opierało się na informacji gradientowej, mapy tej metody były szczególnie podatne na zaburzenia związane z takim typem ataku. Deletion AUC dla Integrated Gradients na MNIST wskazywało na szybki spadek wartości $\overline{AUC}_p$ wraz ze wzrostem ϵ . Dla $\epsilon = 0,010$ wynosiło ono 0,369, natomiast dla $\epsilon = 0,500$ spadło do 0,047. Tego spadku nie należało jednak interpretować jako poprawy jakości map po ataku. Równolegle średnia pewność modelu względem klasy docelowej spadła z 0,993 do 0,167, a liczba zmian predykcji wzrosła z 0 do 83. Oznaczało to, że dla silnego FGSM model często przestawał rozpoznawać klasę docelową jeszcze przed procedurą deletion. Niska wartość AUC była więc związana zarówno ze zmianą mapy atrybucji, jak i z degradacją predykcji.

Dla Occlusion na MNIST metryki podobieństwa przy małych wartościach ϵ pozostawały bardzo wysokie. Dla $\epsilon = 0,010$ podobieństwo cosinusowe wynosiło 0,999, a Top-K IoU 0,963. Przy największej wartości $\epsilon = 0,500$ spadły one odpowiednio do 0,681 i 0,337. Oznaczało to, że Occlusion lepiej zachowywała ogólną strukturę map niż Integrated Gradients, ale lokalizacja najważniejszych regionów również ulegała silnej zmianie przy większych poziomach ataku. Było to zrozumiałe, ponieważ Occlusion zależała od odpowiedzi modelu na zasłanianie fragmentów obrazu. Jeżeli atak zmieniał zachowanie modelu, zmieniały się także oceny istotności poszczególnych regionów. Wyniki Deletion AUC dla Occlusion na MNIST uzupełniały tę obserwację. Dla obrazów czystych $\overline{AUC}_c$ wynosiło 0,184, czyli było niższe niż w przypadku Integrated Gradients. Wskazywało to, że dla niezaburzonych obrazów MNIST regiony wskazywane przez Occlusion skutecznie obniżały pewność modelu po ich usunięciu. Dla obrazów po ataku $\overline{AUC}_p$ spadło z 0,179 dla $\epsilon = 0,010$ do 0,055 dla $\epsilon = 0,500$. Tego przebiegu nie należało jednak interpretować jako jednoznacznej przewagi nad Integrated Gradients w całym zakresie wartości ϵ . Przy większych wartościach ataku wartości $\overline{AUC}_p$ dla Occlusion były

nawet nieco wyższe niż dla Integrated Gradients, co wynikało z odmiennego charakteru map generowanych przez obie metody oraz z silnej degradacji predykcji przy większych perturbacjach. W związku z tym niska wartość Deletion AUC przy silnym FGSM nie oznaczała automatycznie lepszej jakości mapy, lecz musiała być interpretowana razem ze spadkiem pewności modelu i rosnącą liczbą zmian predykcji.

Dla CIFAR-10 wpływ FGSM był szczególnie silny. W przypadku Integrated Gradients już dla $\epsilon = 0,010$ podobieństwo cosinusowe wynosiło 0,762, a Top-K IoU tylko 0,305. Dla $\epsilon = 0,500$ wartości te spadły do 0,507 oraz 0,088. Oznaczało to, że nawet niewielka perturbacja wyraźnie zmieniała położenie najważniejszych obszarów map. Było to zgodne z obserwacjami wizualnymi, w których mapy Integrated Gradients po FGSM dla CIFAR-10 często były silnie osłabione. Umiarkowane wartości podobieństwa cosinusowego nie musiały przeczyć tej obserwacji, ponieważ metryka ta mogła pozostawać względnie wysoka mimo spadku intensywności mapy, jeśli zachowany był częściowy układ wartości. Deletion AUC w tym eksperymencie należało analizować szczególnie ostrożnie. Dla obrazów czystych $\overline{AUC}_c$ wynosiło około 0,185, natomiast dla obrazów po ataku $\overline{AUC}_p$ spadało od 0,145 do 0,070. Jednocześnie już dla $\epsilon = 0,010$ średnia pewność względem klasy docelowej spadła do 0,281, a liczba zmian predykcji wynosiła 29 na 40 przykładów. Przy $\epsilon = 0,075$ zmieniły się wszystkie predykcje. Oznaczało to, że dla CIFAR-10 FGSM bardzo szybko zaburzał nie tylko mapy atrybucji, ale także samą klasyfikację. W takich warunkach niska wartość Deletion AUC mówiła mniej o samej jakości mapy, a więcej o działaniu całego układu: modelu klasyfikacyjnego i metody XAI pod wpływem silnej perturbacji. Niemonotoniczny przebieg liczby zmian predykcji dla większych wartości ϵ należało interpretować jako efekt działania modelu w warunkach skrajnie silnej perturbacji, a nie jako oznakę większej stabilności dla najsilniejszego ataku. Dla średnich wartości parametru FGSM skutecznie przesunął przykłady poza obszar decyzyjny klasy pierwotnej, co prowadziło do największej liczby zmian predykcji. Przy bardzo dużych wartościach ϵ , traktowanych jako test obciążeniowy, obrazy mogły jednak wychodzić poza typowy rozkład danych, a dodatkowe ograniczanie wartości pikseli do zakresu $[-1,1]$ sprawiało, że dalsze zwiększanie perturbacji nie działało już liniowo. W efekcie część predykcji mogła przypadkowo wracać do klasy pierwotnej, mimo że obrazy i mapy atrybucji pozostawały silnie zaburzone.

Dla Occlusion na CIFAR-10 FGSM również powodował duży spadek stabilności. Podobieństwo cosinusowe zmniejszyło się z 0,791 do 0,567, natomiast Top-K IoU z 0,339 do 0,079. Wartości Top-K IoU były bardzo niskie w całym zakresie parametru ϵ , co oznaczało, że po ataku najważniejsze regiony map Occlusion słabo pokrywały się z regionami wskazywanymi dla obrazów oryginalnych. Chociaż Occlusion nie była metodą gradientową, jej wyniki zależały od reakcji modelu na zasłanianie fragmentów obrazu. Gdy FGSM zmieniał predykcję lub istotnie obniżał pewność względem klasy docelowej, mapa Occlusion również traciła zgodność z mapą dla obrazu czystego. Wyniki Deletion AUC dla Occlusion na CIFAR-10 dodatkowo pokazały niemonotoniczny charakter zachowania modelu przy silnym FGSM. Dla obrazów czystych $\overline{AUC}_c$ wynosiło 0,278, natomiast dla obrazów po ataku wartości $\overline{AUC}_p$ były niższe, ale nie

maląy w sposób monotoniczny. Dla $\varepsilon = 0,075$ wynosiły 0,109, następnie wzrosły do 0,180 dla $\varepsilon = 0,150$ i 0,190 dla $\varepsilon = 0,200$, a później ponownie spadły do 0,085 dla $\varepsilon = 0,500$.

Porównanie FGSM dla MNIST i CIFAR-10 wskazywało, że w przypadku danych naturalnych wyjaśnienia były znacznie silniej destabilizowane przez perturbację gradientową. Dla MNIST przy najmniejszej wartości ε nie odnotowano zmian predykcji, natomiast dla CIFAR-10 już przy $\varepsilon = 0,010$ zmieniło się 29 z 40 predykcji. Różnica ta była zgodna z charakterem zbiorów. W MNIST kluczowa informacja była skupiona w prostym kształcie cyfry, natomiast w CIFAR-10 model korzystał z bardziej złożonych cech wizualnych i kontekstu. FGSM, jako atak oparty na gradiencie straty, łatwiej zaburzał takie złożone reprezentacje, co przekładało się również na niższą stabilność map atrybucji.

7. Podsumowanie

Podsumowując porównanie obu metod XAI, Occlusion okazała się bardziej stabilna przestrzennie, szczególnie w warunkach losowego szumu Gaussa. Jej regionalny sposób wyznaczania istotności powodował, że drobne zmiany wartości pikseli nie prowadziły do gwałtownej zmiany układu map. Było to szczególnie widoczne dla zbioru MNIST, gdzie najważniejsze obszary pozostawały związane z kształtem cyfry nawet przy wysokich poziomach szumu. Dla CIFAR-10 stabilność była niższa, ale Occlusion nadal zachowywała bardziej spójny obraz istotnych regionów niż Integrated Gradients.

Integrated Gradients okazało się bardziej wrażliwe na perturbacje obrazu wejściowego. Wynikało to z gradientowego charakteru tej metody, która reagowała na zmiany lokalnej struktury obrazu oraz na zmiany kierunku gradientów modelu. W przypadku losowego szumu prowadziło to do stopniowego osłabienia zgodności map, natomiast w przypadku FGSM wpływ był silniejszy, ponieważ sama perturbacja była wyznaczana na podstawie gradientu funkcji straty. Szczególnie dla CIFAR-10 mapy Integrated Gradients szybko traciły stabilność, co wskazywało, że szczegółowe wyjaśnienia gradientowe były bardziej podatne na zakłócenia danych wejściowych.

Wyniki nie wskazywały jednak na jednoznaczną przewagę jednej metody we wszystkich aspektach. Occlusion była bardziej odporna pod względem zachowania położenia istotnych regionów, ale Integrated Gradients w części eksperymentów, zwłaszcza dla czystych obrazów CIFAR-10, lepiej wskazywało fragmenty funkcjonalnie istotne dla decyzji modelu. Oznaczało to, że stabilność przestrzenna mapy i skuteczność wskazywania elementów krytycznych dla predykcji nie zawsze były równoważne.

Ostatecznie przeprowadzone eksperymenty pokazały, że stabilność metod XAI nie była cechą stałą, lecz zależała od rodzaju danych, typu perturbacji oraz mechanizmu działania danej metody. Occlusion można było uznać za metodę bardziej odporną przestrzennie na losowe zakłócenia, zwłaszcza dla prostszych danych. Integrated Gradients dostarczało bardziej szczegółowych wyjaśnień, jednak ta szczegółowość wiązała się z większą podatnością na perturbacje, zwłaszcza na perturbacje gradientowe. Najtrudniejszym scenariuszem dla obu metod był atak FGSM na zbiorze CIFAR-10, gdzie złożoność obrazów i ukierunkowany charakter perturbacji prowadziły do wyraźnej destabilizacji map atrybucji.